

第 36 讲

练习题与答案

Learning Rate

《面向 LLM / Agent Systems 科研的深度学习零基础课》

建议

先独立完成，再看答案。

练习题

1. 用一句话解释 Gradient 和 Learning Rate 各自回答什么问题。
2. 已知 $w = 5$, Gradient $g = 8$, LR=0.05。按 SGD 更新后 w 是多少？
3. 对 $L(w) = (w - 3)^2$, 当前 $w = 8$ 。分别计算 LR=0.1 和 LR=0.9 的第一步新 w 。哪一个会跨过最优点？
4. 对同一个函数，为什么 LR=1.0 不会收敛？提示：推导 $e_{t+1} = (1 - 2\eta)e_t$ 。
5. 若 $\|g\| = 20$, LR=0.001, SGD 下 Update Norm 是多少？若 LR 增大到 0.01 呢？
6. 判断正误：“同样 lr=0.001, SGD 与 Adam 的真实 Parameter Update 一定一样。”
7. 某训练 Loss 从一开始就在大幅震荡，偶尔跳到 NaN。列出 3 个需要检查的原因，其中至少 1 个不能是“LR 太大”。
8. 为什么比较不同 Batch Size 时，不能只固定 Epoch 数然后直接比较最终 Loss？
9. 某 LLM 配置写着 peak LR= 3×10^{-4} 、warmup=2000 steps。你还需要确认哪些信息，才能理解这个配置？至少写 4 项。
10. 设计一个“只研究 Learning Rate 影响”的最小对照实验，列出必须固定的变量与至少 3 个需要记录的结果。

参考答案

1. Gradient 描述当前点 Loss 对参数变化的局部敏感度和方向；Learning Rate 决定根据这个梯度实际迈多大的更新步长。
2. $w_{new} = 5 - 0.05 \times 8 = 4.6$ 。
3. Gradient 为 $2(8 - 3) = 10$ 。LR=0.1: $w = 7$ ；LR=0.9: $w = -1$ ，后者跨过了最优点 $w = 3$ 。
4. $\eta = 1$ 时 $1 - 2\eta = -1$ ，所以 $e_{t+1} = -e_t$ ，误差只改变符号、不减小，参数在最低点两侧等幅振荡。
5. SGD 下 $\|\Delta\theta\| = \eta\|g\|$ 。分别为 0.02 和 0.2。
6. 错。Adam 会利用一阶/二阶历史统计重新缩放 Gradient；相同 nominal LR 不代表相同实际 Update。
7. 可能原因：LR 太大、Gradient 爆炸、输入/Label 异常、Loss 实现错误、混合精度溢出、参数/数据出现 Inf/NaN 等。
8. 不同 Batch Size 会改变每 Epoch 的 optimizer step 数、Gradient Noise、可能使用的 LR 和实际计算效率。相同 Epoch 不等于相同更新次数或相同训练预算。
9. 至少要确认：Optimizer、warmup 的 step 定义、scheduler 类型、global/effective batch、tokens/update、total optimizer steps 或 total tokens、weight decay、gradient clipping、模型规模等。
10. 固定 Dataset/split、模型结构、初始化/seed、Batch/data order、Optimizer、训练预算、scheduler/regularization。改变 LR。记录是否发散、Loss 曲线、达到某阈值的速度、最终 train/validation 指标、Gradient/Update Norm、多 seed 稳定性等。

自测标准

如果你可以不看答案解释“为什么 LR=0.9 在简单二次函数中可能振荡但仍收敛、LR=1.1 为什么发散”，并能说清 SGD 与 Adam 的 LR 为什么不能直接按数字比较，本讲的核心已经基本掌握。