

第 37 讲

Momentum 实验设计文档

第 37 讲

《面向 LLM / Agent Systems 科研的深度学习零基础课》

实验目标

用可复现的小实验验证 Momentum 的历史记忆、震荡抑制、超参数耦合与 PyTorch 实现。

1 实验问题

1. 持续同方向 Gradient 与正负交替 Gradient 进入 Momentum 后, Buffer 有什么差异?
2. 在狭长 Loss Landscape 中, 相同 LR 下普通 SGD 与 Momentum 的路径有何差异?
3. μ 从 0 增加到 0.99 是否一定更好?
4. 手写 Momentum 能否与 `torch.optim.SGD(momentum=...)` 数值对齐?
5. Momentum 与 Adam first moment 有什么结构联系?

2 实验 1: Gradient 历史

固定:

$$\mu = 0.9$$

对比:

$$[1, 1, 1, 1, \dots]$$

和:

$$[1, -1, 1, -1, \dots]$$


记录:

$$v_t = \mu v_{t-1} + g_t$$

预期: 持续方向 Buffer 逐步增大; 交替方向 Buffer 绝对值明显更小。

实际前 10 Step:

- 持续方向最后 $v \approx 6.5132$;
- 交替方向最后 $v \approx -0.3428$ 。



3 实验 2: 狭长 Loss Landscape

定义:

$$L(w_1, w_2) = \frac{1}{2}(w_1^2 + 50w_2^2)$$

固定:

$$\eta = 0.04, \quad w_0 = [6, 1.5], \quad 80 \text{ Steps}$$

对比:

- SGD: $\mu = 0$;
- Momentum: $\mu = 0.9$ 。



普通 SGD 在 w_2 方向:

$$w_{2,t+1} = w_{2,t} - 0.04 \times 50w_{2,t} = -w_{2,t}$$

因此产生持续横向翻转。

实际结果:

方法	初始 Loss	80 Step 后 Loss
SGD	74.25	56.2762
Momentum $\mu = 0.9$	74.25	0.00608



4 实验 3：Momentum coefficient 扫描


固定其他条件，仅改变：

$$\mu \in \{0, 0.5, 0.9, 0.95, 0.99\}$$

最终结果显示：本例 $\mu = 0.5$ 最快， $\mu = 0.99$ 明显较差。

实验结论边界

这个实验只证明： μ 更大不保证更好。不能据此推出“0.5 是通用最佳 Momentum”。真正最佳值与 LR、曲率、Gradient Noise、训练阶段共同相关。



5 实验 4：手写 Momentum 与 PyTorch 对齐

使用二维参数：

$$p = [2, -1]$$

Loss：

$$L = \frac{1}{2}(p_1^2 + 3p_2^2)$$

因此：

$$g = [p_1, 3p_2]$$

固定：

$$\eta = 0.05, \quad \mu = 0.9$$

连续 8 Step，同时：

1. NumPy 手写 $v_t = \mu v_{t-1} + g_t$;
2. PyTorch 使用 `torch.optim.SGD(momentum=0.9)`;
3. 比较每一步 Parameter。

最大差异仅约 10^{-16} ，属于浮点误差级别。

6 实验 5：连接 Adam

对同一 Gradient Sequence 同时计算：

$$b_t = \mu b_{t-1} + g_t$$

和：

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

观察两者都利用历史 Gradient，但尺度定义不同。Adam 后续还会加入 second moment 与 bias correction。

7 控制变量与可复现性

- 固定起点；
- 固定 LR；
- 扫描 μ 时只改变 μ ；
- PyTorch 对齐实验采用 float64，减少数值误差；
- 保存实际控制台输出；
- 保存所有图像；
- 不把小型二次函数实验的最佳超参数外推到真实深度网络。

8 科研式结果解释

可以支持的结论：

1. Momentum 确实会累积持续方向的历史 Gradient；
2. 在本实验的狭长二次 Loss 中，它显著改善了普通 SGD 的横向震荡问题；
3. μ 过大时可能表现更差；
4. PyTorch 的 Momentum 与手写更新公式数值一致。

不能直接支持的结论：

- Momentum 在所有任务都优于 SGD；
- $\mu = 0.5$ 比 0.9 普遍更优；
- Training Loss 更快下降就意味着 Test Generalization 更好；
- 二次函数中的稳定性边界可以直接照搬到 LLM。

9 运行方式

```
python lesson37_momentum_experiment.py
```

输出包括：控制台结果 TXT 与多个 PNG 图。