

第 37 讲

Momentum 核心概念速查卡

第 37 讲复习用

《面向 LLM / Agent Systems 科研的深度学习零基础课》

定位

只用于复习；详细解释请看完整讲义。

1. 最核心公式

$$v_t = \mu v_{t-1} + g_t$$

$$\theta_{t+1} = \theta_t - \eta v_t$$

g_t : 当前 Gradient; v_t : Momentum Buffer; μ : 历史保留系数; η : Learning Rate。

2. 直觉

- 持续同方向 Gradient: Buffer 累积, 趋势被强化。
- 正负交替 Gradient: 历史部分抵消, 震荡被抑制。
- $\mu = 0$: 退化为普通 SGD。
- μ 越接近 1: 记忆越长, 但不保证越好。

3. 展开式

$$v_t = g_t + \mu g_{t-1} + \mu^2 g_{t-2} + \dots$$

过去第 k 步 Gradient 权重约为 μ^k 。

4. 必须区分

Gradient	当前点的局部方向信息
Momentum Buffer	带历史记忆的 Gradient 趋势
Learning Rate	把 buffer 转换成实际 Parameter Update 的尺度
Optimizer State	Buffer 等跨 Step 保存的状态

5. PyTorch

```
optimizer = torch.optim.SGD(  
    model.parameters(),  
    lr=0.05,  
    momentum=0.9  
)
```

6. 与 Adam 的关系

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

Adam first moment 与 Momentum 都在利用历史 Gradient；Adam 还会使用 second moment，并做 bias correction。

三条防错

1. μ 越大不等于越好。
2. Momentum 与 LR 必须联合看。
3. Training Loss 更快下降不等于 Generalization 更好。