

第 37 讲

Momentum 练习题与答案

第 37 讲

《面向 LLM / Agent Systems 科研的深度学习零基础课》

使用方法

先独立做，再看答案。

练习题

1. 用一句话解释：为什么普通 SGD 在狭长 Loss Valley 中容易左右震荡？
2. 设 $\mu = 0.9, v_0 = 0$, Gradient 依次为 $[2, 2, -1]$ 。求 v_1, v_2, v_3 。
3. 如果 $\mu = 0$, Momentum 更新退化为什么？
4. 为什么“ μ 越大越好”是错误说法？
5. 区分 Momentum Buffer 与模型 Parameter。
6. 写出 PyTorch 中带 Momentum 的 SGD 初始化代码，设 $lr = 0.01, momentum = 0.9$ 。
7. 为什么加入 Momentum 后，即使 LR 不变，实际 Update Norm 也可能改变？
8. Adam 的 β_1 与本讲 Momentum 有什么概念联系？
9. 论文比较 SGD 与 SGD+Momentum 时，至少还应该同时报告哪些训练设置？
10. 为什么 `optimizer.zero_grad()` 不应该把 momentum buffer 一起清掉？
11. 模型断点恢复时，为什么只保存 `model.state_dict()` 可能无法精确延续原训练轨迹？
12. 区分“Momentum 的指数衰减加权”和“标准 EMA”。

答案

1. 陡峭方向 Gradient 容易在谷底两侧反复变号，普通 SGD 每步只看当前 Gradient，因此会不断横向来回跳。
2. $v_1 = 2$; $v_2 = 0.9 \times 2 + 2 = 3.8$; $v_3 = 0.9 \times 3.8 - 1 = 2.42$ 。
3. $v_t = g_t$, 所以 $\theta_{t+1} = \theta_t - \eta g_t$, 即普通 SGD。
4. 更大的 μ 会保留更久的历史，也可能造成惯性过强、overshoot、振荡或对新方向响应迟缓；效果还与 LR、曲率、Noise 耦合。
5. Parameter 是模型 Forward 中的可训练变量；Momentum Buffer 是 Optimizer 为更新 Parameter 保存的跨 Step 状态，通常不参与 Forward。
6. `torch.optim.SGD(model.parameters(), lr=0.01, momentum=0.9)`。
7. 因为最终更新使用 $-\eta v_t$, 而 v_t 是多个历史 Gradient 的累积，不再等于当前 g_t 。
8. 都会保存历史 Gradient 的一阶趋势；Adam 的 first moment 是带归一化系数的指数移动平均思想，并进一步配合 second moment 与 bias correction。

9. LR、Batch / Effective Batch、Scheduler、总 Steps / Tokens、Gradient clipping、Weight decay，以及是否分别为各优化器调参。
10. 因为 Momentum 的意义就是跨 Step 保存历史。如果每次把 buffer 清零，就只剩当前 Gradient，失去历史记忆。
11. 因为 momentum buffer 等 Optimizer State 不在 model state 中；只恢复模型权重会丢失优化器历史，导致后续更新轨迹改变。
12. PyTorch-style $v_t = \mu v_{t-1} + g_t$ 是指数衰减加权和，恒定 Gradient 下尺度可趋近 $1/(1 - \mu)$ ；EMA 常写成 $m_t = \mu m_{t-1} + (1 - \mu)g_t$ ，权重被归一化，恒定输入下趋近输入本身。