

第 38 讲

实验设计文档

Adam：一阶矩、二阶矩、Bias Correction 与自适应更新

《面向 LLM / Agent Systems 科研的深度学习零基础课》

实验目标

不是“跑一下 Adam 看 Loss 会不会下降”，而是逐个验证 Adam 公式中每个组件的行为，并把手写公式与 PyTorch 实现对齐。

1 研究问题与假设

RQ1: m_t 与 v_t 分别怎样响应 Gradient 历史？

RQ2: bias correction 是否真的修复 0 初始化导致的早期尺度偏差？

RQ3: Adam 是否会对不同 Gradient 尺度的坐标产生不同的有效缩放？

RQ4: 手写 Adam 与 `torch.optim.Adam` 是否数值一致？

RQ5: ϵ 在极小 second moment 区域是否会影响实际更新？

2 实验 1：5 Step Adam 内部状态追踪

固定：

$$\theta_0 = 5, \quad lr = 0.1, \quad \beta_1 = 0.9, \quad \beta_2 = 0.999$$

Gradient 序列：

$$[2, 2, 1, -1, 0.5]$$

每 Step 记录： $g, m, v, \hat{m}, \hat{v}, update, \theta$ 。

观察重点：当前 Gradient 变为负数后， m_t 是否会因为历史仍保持正方向。

3 实验 2：Bias Correction

构造恒定 Gradient：

$$g_t = 2$$



比较：

$$m_t \quad \text{vs} \quad \hat{m}_t$$

以及：

$$\frac{m_t}{\sqrt{v_t}} \quad \text{vs} \quad \frac{\hat{m}_t}{\sqrt{\hat{v}_t}}$$

实验结果表明，未校正的 first moment 早期明显偏小；由于 β_1, β_2 不同，未校正的最终归一化比例甚至会被扭曲到大于 1。校正后恒定正 Gradient 的比例稳定为 1。



4 实验 3: 坐标级自适应

固定:

$$g = [100, 1], \quad lr = 0.1$$

比较 SGD 与 Adam 第一步。

SGD:

$$|\Delta\theta| = [10, 0.1]$$

Adam:

$$|\Delta\theta| \approx [0.1, 0.1]$$

控制变量：同一个 Gradient、同一个 nominal LR；只改变 optimizer 规则。

结论边界：这是第 1 Step 的教学极简例子，不代表 Adam 后续每一步都等幅更新。


5 实验 4: SGD / Momentum / Adam 轨迹


使用:

$$L = \frac{1}{2}(w_1^2 + 100w_2^2)$$

该 Loss 在两个方向的曲率相差 100 倍。

分别运行 SGD、Momentum、Adam，记录参数轨迹和 Loss。





方法学边界

本实验为展示机制，为不同优化器使用了不同 LR，因此不能作为“谁更好”的公平 benchmark。若做正式论文比较，应给各方法合理调参预算，并控制计算预算、随机种子、Batch、Scheduler 等。

6 实验 5: 手写 Adam vs PyTorch

定义:

$$L = \frac{1}{2}(p_1^2 + 3p_2^2)$$

用 float64 运行 8 Step:

- 路径 A: NumPy 手写 Adam;
- 路径 B: `torch.optim.Adam`;
- 每一步比较 Parameter 最大绝对差。

实际最大差异约 10^{-16} ，为浮点误差量级。

同时读取 PyTorch optimizer state:

- `step`;
- `exp_avg`;
- `exp_avg_sq`。


7 实验 6: ϵ 的影响

扫描极小 Gradient, 固定:

$$lr = 0.001$$

比较：

$$\epsilon = 10^{-8}, 10^{-6}, 10^{-4}$$



结果说明：当 $|g| \gg \epsilon$ 时影响很小；当 $|g|$ 与 ϵ 同量级或更小时，实际更新会被明显改变。

8 实验执行

运行：

```
python lesson38_adam_experiment.py
```

输出：第 38 讲 _ 实验实际输出.txt，图像位于 figures/。

9 实验验收标准

1. 能解释每张图验证的具体假设；
2. 能手算第一 Step 的 $m, v, \hat{m}, \hat{v}$ ；
3. 能说明为什么 v_t 不是简单“方差”；
4. 能解释为什么 Gradient Accumulation 改变 Adam state 更新频率；
5. 能说明手写 Adam 与 PyTorch 对齐验证的是“实现正确性”，不是“Adam 一定更好”。