

第 38 讲

核心概念速查卡

Adam Optimizer

《面向 LLM / Agent Systems 科研的深度学习零基础课》

用途

复习公式、变量含义和 PyTorch 对照。

Adam 五步公式

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}$$

$$\theta_t = \theta_{t-1} - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

变量

g_t	当前 Gradient
m_t	Gradient 的一阶指数移动平均，保留方向信息
v_t	Gradient 平方的二阶指数移动平均（不是简单“方差”）
β_1	一阶历史记忆，常见 0.9
β_2	二阶尺度历史记忆，常见 0.999
η	nominal learning rate
ϵ	数值稳定项，也可能影响极小 second moment 区域的更新

直觉

- m_t : 最近“通常往哪边走”；
- v_t : 这个坐标最近 Gradient “通常有多大”；
- $m/\sqrt{v}$: 按自身尺度归一化后的方向；
- bias correction: 补偿从 0 初始化带来的早期偏差；
- Adam state 跨 Step 保存，`zero_grad()` 不会清它。

PyTorch

```
optimizer = torch.optim.Adam(
    model.parameters(),
    lr=1e-3,
```

```
    betas=(0.9, 0.999),  
    eps=1e-8,  
)
```

Optimizer state 常见: `step`, `exp_avg`, `exp_avg_sq`。

科研检查清单

Adam/AdamW、LR、 β_1 、 β_2 、 ϵ 、warmup、scheduler、weight decay、global batch/tokens、gradient clipping、optimizer steps。