

第 38 讲

练习题与答案

Adam Optimizer

《面向 LLM / Agent Systems 科研的深度学习零基础课》

建议

先独立完成，再看答案。

练习题

1. 用一句话分别解释 m_t 与 v_t 在 Adam 中记录什么。
2. 为什么 v_t 不宜直接称为 Gradient 方差？
3. 若 $\beta_1 = 0.9, m_0 = 0, g_1 = 4$ ，求 m_1 与 $\hat{m}_1$ 。
4. 若 $\beta_2 = 0.999, v_0 = 0, g_1 = 4$ ，求 v_1 与 $\hat{v}_1$ 。
5. 第一步中若忽略 ϵ ， $g = [100, 1]$ ，bias-corrected Adam 的 $\hat{m}/\sqrt{\hat{v}}$ 大约是多少？
6. 为什么 `optimizer.zero_grad()` 不会把 Adam 的历史状态恢复为 0？
7. Gradient Accumulation=4 时，Adam 的 step index 通常是按 micro-batch 还是 optimizer update 增加？
8. 为什么只保存 `model.state_dict()` 不能严格恢复 Adam 的训练轨迹？
9. 判断：Adam 使用自适应缩放，所以学习率不再重要。对还是错？解释。
10. 论文只写 “Adam, lr=1e-3”，为了复现至少还应追问哪些训练配置？

答案

1. m_t 记录带符号 Gradient 的近期平均方向； v_t 记录 Gradient 平方的近期平均尺度。
2. 因为它近似的是 $E[g^2]$ 的 uncentered second moment, 而不是中心化的 $E[(g - E[g])^2]$ 。
3. $m_1 = 0.9 \times 0 + 0.1 \times 4 = 0.4$; $\hat{m}_1 = 0.4 / (1 - 0.9) = 4$ 。
4. $v_1 = 0.001 \times 16 = 0.016$; $\hat{v}_1 = 0.016 / (1 - 0.999) = 16$ 。
5. $[1, 1]$ (更准确说正坐标约为 +1), 所以第一步实际更新尺度接近同一个 nominal LR。
6. 因为 zero_grad 清的是 Parameter 的 `.grad`, Adam 的 $m, v, step$ 属于 optimizer state。
7. 通常按 optimizer update 增加; 4 个 micro-batch 累积后 step 一次, Adam state 更新一次。
8. 因为丢失了 $m_t, v_t, step$, 恢复后 optimizer 历史从头开始。
9. 错。Adam 仍有全局 nominal LR, 且常是关键超参数; 自适应只改变各坐标的有效缩放。
10. 至少包括 betas、eps、Adam 还是 AdamW、weight decay、scheduler、warmup、batch/effective batch、total optimizer steps/tokens、gradient clipping 等。