

第 39 讲

实验设计：AdamW 与 Weight Decay

验证 L2、Coupled Adam、Decoupled AdamW 的差异

《面向 LLM / Agent Systems 科研的深度学习零基础课》

实验原则

本实验的目标不是证明“AdamW 一定比 Adam 泛化好”，而是验证它们的**更新机制确实不同**。所有结论都限制在对应实验条件内。

1 实验问题

1. 基础 SGD 中，L2 penalty 与 weight decay 是否严格等价？
2. data gradient=0 时，Adam(coupled) 和 AdamW(decoupled) 会怎样衰减不同尺度的参数？
3. coupled weight decay 是否会进入 Adam 的 moment state？
4. 显式 L2 penalty 与 Adam(weight_decay=...) 是否对齐？
5. 当前 PyTorch 中 AdamW 与 Adam(decoupled_weight_decay=True) 是否对齐？
6. 相同 weight decay、不同 LR schedule，累计 shrink 是否不同？
7. 小回归任务中，不同语义是否会产生不同的 loss / parameter norm 轨迹？

2 控制变量

- 所有关键比较固定相同初始参数；
- 手工指定相同 data gradient；
- 比较 Adam vs AdamW 时固定 lr、betas、eps、weight decay；
- 小回归实验固定 random seed、网络结构、初始化与训练步数；
- 不把玩具实验的 training loss 差异解释为通用泛化结论。

3 实验 1：SGD 等价性

设置：

$$w = [3, -2], \quad g = [0.5, -1.5], \quad \eta = 0.1, \quad \lambda = 0.2$$

比较：

$$w - \eta(g + \lambda w)$$

与：

$$(1 - \eta\lambda)w - \eta g$$

预期：完全一致。

实际结果：

$$[2.89, -1.81]$$

两种写法最大误差为 0。

4 实验 2: data gradient=0 的第一步

设置:

$$\theta = [10, 1, 0.1], \quad \eta = 0.01, \quad \lambda = 0.1$$

故意令:

$$g_{data} = 0$$


这样可以单独观察 weight decay 机制。

Adam(coupled):

$$[9.99, 0.99, 0.090000001]$$

AdamW:

$$[9.99, 0.999, 0.0999]$$



同时检查 state: Adam 的 m, v 非零; AdamW 的 m, v 仍为 0。


5 实验 3: 50 Step 纯 decay 轨迹

持续令 data gradient=0。

AdamW 从 10 开始:

$$10(1 - 0.01 \times 0.1)^{50} \approx 9.512056$$

实际完全一致。



6 实验 4：显式 L2 与 Adam(weight_decay) 对齐

对显式 penalty:

$$\frac{\lambda}{2} \|w\|^2$$

其额外 Gradient 是:

$$\lambda w$$

实验直接把这个 Gradient 加到 data gradient 中, 与 Adam(weight_decay=lambda) 比较。

结果最大误差:

$$0$$

说明当前 coupled 语义对齐。

7 实验 5：PyTorch decoupled 接口对齐

本实验环境: PyTorch 2.10。比较:

```
torch.optim.AdamW(...)
torch.optim.Adam(..., decoupled_weight_decay=True)
```

连续 8 Step 最大误差:

$$0$$

注意: 不同 PyTorch 版本 API 可能不同, 跨环境复现应检查版本。

8 实验 6：LR Schedule 与累计 Decay

只考虑 AdamW decay:

$$\theta_{t+1} = (1 - \eta_t \lambda) \theta_t$$


100 Step, $\lambda = 0.1$ 。

恒定 $lr = 0.01$:

$$\theta_T / \theta_0 \approx 0.90479$$

Cosine LR:

$$\theta_T/\theta_0 \approx 0.95121$$




9 实验 7: 小回归机制演示

比较: No WD、Adam coupled WD、AdamW。

最终:

设置	Data MSE	Parameter norm
No WD	0.02308	5.2633
Adam coupled	0.05080	2.7085
AdamW	0.03333	3.9603



结果边界

这里不比较 Test Set, 也没有调参, 所以不能据此断言哪种 optimizer 泛化最好。该实验只证明相同 weight decay 数值在不同算法里会产生不同轨迹。

10 实验验收标准

你应该能够回答：

1. 为什么 SGD 中等价, 而 Adam 中不再简单等价?
2. 为什么 coupled Adam 的 moment state 会被 decay 项影响?
3. 为什么 AdamW 的 decay 是按 Parameter 大小比例收缩?
4. 为什么 LR schedule 会改变累计 decay?
5. 为什么不能仅凭 `weight_decay=0.1` 判断两个实验设置相同?