

第 39 讲

AdamW 与 Weight Decay 速查卡

L2、Coupled Adam、Decoupled AdamW 的核心区别

《面向 LLM / Agent Systems 科研的深度学习零基础课》

一句话

基础 SGD 中 L2 penalty 与 weight decay 可代数等价；Adam 会对 Gradient 做自适应变换，所以把 $\lambda\theta$ 塞进 Gradient 不再等价于直接按比例衰减参数。AdamW 的核心就是把 weight decay 与 Adam moment estimation 解耦。

1. L2 Regularization

$$J(\theta) = L_{data}(\theta) + \frac{\lambda}{2} \|\theta\|_2^2$$

$$\nabla J = g_{data} + \lambda\theta$$

2. 基础 SGD：两种写法等价

$$\theta' = \theta - \eta(g + \lambda\theta)$$

$$\theta' = (1 - \eta\lambda)\theta - \eta g$$

3. Adam coupled

先构造：

$$g^{coupled} = g_{data} + \lambda\theta$$

然后这个 Gradient 进入：

$$m_t, \quad v_t$$

所以 decay 项被 Adam 自适应机制加工。

4. AdamW decoupled

概念式：

$$\theta_t = (1 - \eta_t\lambda)\theta_{t-1} - \eta_t \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

其中 m, v 只基于 data gradient。

5. 关键数字例子

$g_{data} = 0, \theta = [10, 1, 0.1], \eta = 0.01, \lambda = 0.1$ ：

- Adam coupled 第一步约变为 $[9.99, 0.99, 0.09000001]$ ；

- AdamW 第一步变为 $[9.99, 0.999, 0.0999]$ 。

6. PyTorch

```
# coupled L2 semantics
opt = torch.optim.Adam(model.parameters(),
                        lr=3e-4,
                        weight_decay=0.1)

# decoupled weight decay
opt = torch.optim.AdamW(model.parameters(),
                        lr=3e-4,
                        weight_decay=0.1)
```

7. 必须记住的科研点

- weight decay 的实际累计强度取决于 LR schedule 和 optimizer steps;
- parameter groups 可能对 bias / norm 参数设置 $wd = 0$;
- 相同 weight decay 数值, 不同 optimizer 语义不可直接当成同一实验;
- Training Loss / parameter norm 不能直接推出 Generalization;
- 记录 optimizer、lr、betas、eps、wd、scheduler、parameter groups。