

第 39 讲

第 39 讲练习题与答案

AdamW 与 Weight Decay

《面向 LLM / Agent Systems 科研的深度学习零基础课》

使用方法

先独立完成，再看答案。重点不是机械代公式，而是判断 “regularization 到底进入了哪里”。

练习题

1. 写出带 L2 penalty 的目标函数，并说明为什么常写 $\frac{\lambda}{2}\|\theta\|^2$ 。
2. 若 $w = 4$ ，data gradient $g = 1.5$ ， $\lambda = 0.1$ ，求加入 L2 后的总 Gradient。
3. 对基础 SGD，证明：

$$w' = w - \eta(g + \lambda w)$$

可写为：

$$w' = (1 - \eta\lambda)w - \eta g$$

4. 为什么上面的等价关系不能直接搬到 Adam？
5. AdamW 中若 $\eta = 0.002$ 、 $\lambda = 0.1$ ，仅考虑 decay，一步的参数乘法因子是多少？
6. 参数 $[10, 1]$ ，若仅做 AdamW decay，上一题的设置下一步分别减少多少？
7. 判断正误：weight_decay=0.1 意味着每步参数乘 0.9。
8. 为什么 AdamW 的 weight decay 强度会受到 LR scheduler 影响？
9. 为什么某些 LLM recipe 会把 bias / LayerNorm / RMSNorm 参数放进 no-decay group？这个做法是数学定律吗？
10. 一篇论文比较两种方法，但方法 A 用 AdamW，方法 B 用 Adam，二者都写 weight decay=0.1。你会检查什么？

答案

1.

$$J = L_{data} + \frac{\lambda}{2} \|\theta\|^2$$

前面的 $1/2$ 让求导后直接得到 $\lambda\theta$ ，书写更整洁。

2.

$$g_{total} = 1.5 + 0.1 \times 4 = 1.9$$

3. 直接展开：

$$w - \eta g - \eta \lambda w = (1 - \eta \lambda)w - \eta g$$

4. 因为 Adam 会把 Gradient 送入一阶矩、二阶矩、bias correction 和坐标级归一化。若 λw 被塞进 Gradient，它也会被这些机制加工，不再只是简单比例 shrink。

5.

$$1 - 0.002 \times 0.1 = 0.9998$$

6. 对 10：减少 $10 \times 0.0002 = 0.002$ ；对 1：减少 0.0002。

7. 错。AdamW 单步 decay factor 是 $1 - \eta\lambda$ ，还必须乘 Learning Rate。

8. 因为每步 shrink factor 含 η_t 。LR 随 step 改变，累计乘积 $\prod_t (1 - \eta_t \lambda)$ 也改变。

9. 常见动机是这些一维偏置 / 归一化尺度参数不一定希望按同样方式衰减。但它只是训练 recipe，不是数学定律，必须遵循具体论文 / 代码设置。

10. 至少检查 optimizer 语义、PyTorch / 框架版本、是否 decoupled、parameter groups、LR 和 scheduler、总 optimizer steps，以及是否只是变量名相同但算法不同。