

第 40 讲

实验设计

Initialization、Vanishing / Exploding Gradient

《面向 LLM / Agent Systems 科研的深度学习零基础课》

实验原则

每个实验只验证一个核心机制，先提出假设，再观察数值与图，不把单次小实验外推成所有网络的普遍结论。

1 实验总目标

本讲不追求训练复杂模型，而是用最小可复现实验回答六个问题：

1. 全零初始化是否真的让对称隐藏神经元收到相同 Gradient？
2. Weight Scale 过小/过大时，深层 ReLU Activation 怎样变化？
3. Chain Rule 中连续乘小于 1 或大于 1 的局部导数会发生什么？
4. Tanh 饱和区的导数是否真的接近 0？
5. Gradient Clipping 是否能把 global grad norm 限制到阈值？
6. PyTorch Xavier/Kaiming API 生成的实际标准差是否符合理论量级？

2 实验 1：Zero Initialization 与 Symmetry


假设：两个隐藏神经元如果完全对称且都从 0 开始，会得到相同 Gradient，更新后仍保持相同。

控制变量：输入、Loss、第二层连接完全一致，只观察第一层两列 Weight Gradient。

结果：

$$W_1.grad = \begin{bmatrix} -2 & -2 \\ 4 & 4 \end{bmatrix}$$

更新后两列仍相同，支持假设。




3 实验 2: Initialization Scale 与 Activation Propagation

固定：30 层、宽度 256、ReLU、同分布输入。仅改变 Weight 初始化标准差。

比较：

- small: $std = 0.01$;
- large: $std = 0.20$;
- Xavier-like: $\sqrt{1/fan_{in}}$;
- He: $\sqrt{2/fan_{in}}$ 。

关键结果：small 最终 std 约 1.91×10^{-29} ；large 达 1.66×10^{10} ；He 最终约 0.599。




4 实验 3: Chain Rule 中的梯度尺度

构造理想化乘积：

$$G_L = a^L$$

让 $a \in \{0.5, 0.9, 1.0, 1.1, 1.5\}$ ，观察深度从 1 到 30。

结果验证： $a < 1$ 指数衰减， $a > 1$ 指数放大。



5 实验 4: Tanh Saturation


取：

$$z = [-5, -2, 0, 2, 5]$$

Autograd 得到导数：

$$[1.82 \times 10^{-4}, 0.07065, 1, 0.07065, 1.82 \times 10^{-4}]$$

验证饱和区导数接近 0。




6 实验 5: Global Gradient Norm Clipping

人为设置大 Gradient: clipping 前 global norm 约 223.6068, 调用:

```
torch.nn.utils.clip_grad_norm_(params, max_norm=10.0)
```

后 norm 约为 10.0000。



7 实验 6: PyTorch Initialization API

对 512×512 Weight:

- `xavier_normal_`: 实测 std ≈ 0.04415 ;
- `kaiming_normal_`: 实测 std ≈ 0.06264 。

与理论量级 $\sqrt{1/512}$ 、 $\sqrt{2/512}$ 接近。

8 实验结论边界

不要过度外推

本实验验证的是机制，不是在宣布“所有 Transformer 都应该用某一个初始化公式”。真实 LLM 还包含 Residual、Normalization、GELU/SiLU、多分支结构、混合精度、不同深度与宽度，初始化通常是整个训练 recipe 的一部分。

建议科研记录：seed、初始化函数、fan mode、activation、global grad norm、clipping threshold、LR、Optimizer、Normalization 与异常 Step。