

第 40 讲

核心概念速查卡

Initialization、Vanishing / Exploding Gradient

《面向 LLM / Agent Systems 科研的深度学习零基础课》

用途

用于第 40 讲复习。先理解完整讲义，再用本卡快速回忆。

1. Initialization 三个目标

- 打破隐藏神经元对称性；
- 控制 Forward Activation 尺度；
- 控制 Backward Gradient 尺度。

2. 为什么不能隐藏层 Weight 全 0?

相同初值 + 相同计算路径 $\Rightarrow$ 相同 Gradient $\Rightarrow$ 继续保持相同，神经元退化成复制品。

Bias 可以常设为 0，只要 Weight 已经随机打破对称性。

3. fan-in / fan-out

$$fan_in = D_{in}, \quad fan_out = D_{out}$$

Xavier Normal 常见：

$$Var(W) = \frac{2}{fan_in + fan_out}$$

He / Kaiming for ReLU：

$$Var(W) \approx \frac{2}{fan_in}$$

4. Vanishing / Exploding Gradient

Chain Rule：

$$\frac{\partial L}{\partial x_0} = \frac{\partial L}{\partial x_L} \prod_k \frac{\partial x_k}{\partial x_{k-1}}$$

很多因子 < 1 ：梯度消失；很多因子 > 1 ：梯度爆炸。

5. Activation 与 Gradient

- Sigmoid / Tanh 饱和区：导数接近 0；
- ReLU 正区间导数 1，负区间导数 0；
- GELU / SiLU 更平滑，但不能保证永不出现梯度问题。

6. Gradient Clipping

若 $\|g\|_2 > C$:

$$g \leftarrow g \frac{C}{\|g\|_2}$$

PyTorch:

```
loss.backward()  
clip_grad_norm_(model.parameters(), max_norm=1.0)  
optimizer.step()
```

7. PyTorch 初始化

```
nn.init.xavier_normal_(layer.weight)  
nn.init.kaiming_normal_(layer.weight, nonlinearity="relu")  
nn.init.zeros_(layer.bias)
```

8. 最低诊断项

Activation Mean/Std、Global Gradient Norm、各层 Gradient、LR、初始化方法、是否出现 NaN/Inf。