

第 40 讲

练习题与答案

Initialization、Vanishing / Exploding Gradient

《面向 LLM / Agent Systems 科研的深度学习零基础课》

建议

先独立完成，再看答案。

练习题

1. 两个隐藏神经元的 Weight 和 Bias 都完全相同，而且结构完全对称。为什么训练后它们仍可能一直学成一样？
2. Bias 是否绝对不能初始化为 0？说明理由。
3. 一个 Linear Layer 的 $D_{in} = 256, D_{out} = 512$ 。写出 fan-in 和 fan-out。
4. 对 ReLU 网络，He 初始化的标准差量级为什么常写为 $\sqrt{2/fan_in}$ ？你不需要严格证明，只说明直觉。
5. 连续 20 层的局部导数都约为 0.5，最前端梯度相对末端大约乘了多少？
6. 连续 20 层的局部导数都约为 1.5，又会发生什么？
7. 为什么 Tanh 在 $z = 5$ 附近容易导致 Gradient 变小？
8. Gradient Clipping 把 global grad norm 从 200 限制到 10。它改变的是方向还是主要改变长度？
9. 如果训练每一步都触发 clipping，能否直接说明“问题已解决”？为什么？
10. 阅读代码并解释每一行：

```
nn.init.kaiming_normal_(layer.weight, nonlinearity="relu")
loss.backward()
torch.nn.utils.clip_grad_norm_(model.parameters(), 1.0)
optimizer.step()
```

答案

1. 因为它们 Forward 完全相同, Backward 的依赖路径也相同, 所以收到相同 Gradient; 相同更新后仍保持相同, symmetry 没被打破。
2. 不是。Bias 常可初始化为 0, 只要 Weight 已随机化, 隐藏单元仍有不同 pre-activation, 可以打破对称性。
3. $fan_in = 256$, $fan_out = 512$ 。
4. ReLU 会把负半轴置 0, 使一部分信号消失; He 初始化把 Weight 方差适当放大到约 $2/fan_in$, 用于维持更合适的 Activation 尺度。
5. $0.5^{20} \approx 9.54 \times 10^{-7}$, 属于典型的梯度消失量级。
6. $1.5^{20} \approx 3325$, 梯度会被大幅放大, 可能导致 exploding gradient。
7. 因为 $\tanh'(z) = 1 - \tanh^2(z)$; 当 $z = 5$ 时 $\tanh(z) \approx 1$, 所以导数接近 0。
8. Global norm clipping 主要按相同比例缩小所有 Gradient, 整体方向近似保持, 长度被限制。
9. 不能。Clipping 可能只是抑制症状; 还应检查 LR、Initialization、数据尺度、数值稳定性和模型结构。
10. 第一行设置适合 ReLU 的 Weight 初值; 第二行计算 Gradient; 第三行在更新前限制 Gradient Norm; 第四行由 Optimizer 修改 Parameter。