

第 41 讲

实验设计

Overfitting、Generalization Gap 与 Early Stopping

《面向 LLM / Agent Systems 科研的深度学习零基础课》

实验原则

同一数据分布、固定随机种子、控制主要训练设置；用独立 Validation 选 checkpoint，用 Test 只做最终评估。

1 实验总目标

用最小可复现实验回答五个问题：

1. 模型容量过低、适中、过高时 Train/Validation/Test 会怎样变化？
2. 高容量模型是否会出现 Train Loss 继续下降、Validation Loss 反升？
3. 用最佳 Validation checkpoint 是否能改善独立 Test 表现？
4. 高容量网络能否记住完全随机的标签？
5. 为什么不能只凭 Training Loss 宣称模型真正学会？

2 实验 1：模型容量对拟合形状的影响


数据规律：

$$y = \sin(3x) + 0.3x + noise$$

训练集只有 24 个带噪声样本。比较 Linear、Small MLP、Large MLP，其他主要训练设置保持一致。

最终结果：

模型	Train MSE	Validation MSE	Test MSE
Linear	0.163446	0.244899	0.238305
Small	0.032329	0.104096	0.111837
Large	0.002010	0.152615	0.161832



3 实验 2: Train/Validation 曲线与 Gap



Large MLP 最佳 Validation 出现在 Epoch 111:

$$Train = 0.034981, \quad Val = 0.095893$$

最终:

$$Train = 0.002010, \quad Val = 0.152615$$

验证 Train 持续变好而 Validation 反向恶化。



4 实验 3: Validation 选择最佳 Checkpoint


使用最佳 Validation checkpoint:

$$Test\ MSE = 0.101043$$

训练到最后:

$$Test\ MSE = 0.161832$$

Test 不参与挑 Epoch, 只用于最后比较。




5 实验 4: Random Labels Memorization

输入与标签独立随机, 因此不存在稳定可泛化规律。高容量分类 MLP 训练 1000 Epoch 后:

$$Train\ Accuracy = 100\%$$

$$Validation\ Accuracy \approx 49.8\%$$

验证“记住训练集”和“学到规律”不是同一件事。



6 结论边界

不要过度外推

本实验是机制演示, 不是在证明“大模型一定过拟合”或“Early Stopping 永远最好”。真实任务还受到数据规模、模型预训练、Regularization、Optimizer、数据增强、分布变化等共同影响。

科研记录至少应包括: split 规则、seed、模型容量、训练 Epoch/Step、最佳 Validation Epoch、Test 是否参与调参、Train/Val/Test 指标、数据泄漏检查。