

第 41 讲

练习题与答案

Overfitting 与 Generalization

《面向 LLM / Agent Systems 科研的深度学习零基础课》

使用方法

先独立作答，再看答案。重点不是背术语，而是能根据曲线和实验设置判断问题。

练习题

1. 某模型 Train Loss 从 0.8 降到 0.01，Validation Loss 从 0.9 降到 0.2 后又升到 0.45。最可能发生了什么？
2. 为什么 “Training Accuracy=100%” 不能证明模型真正学到了可泛化规律？
3. 若 Train Loss=0.02，Validation Loss=0.15，在同一 MSE 口径下，简单 Generalization Gap 是多少？
4. Early Stopping 应该看 Validation 还是 Test？为什么？
5. 一个高容量模型比小模型 Training Loss 更低，但 Test 更差，这能否直接证明 “大模型天然泛化差”？
6. 如果同一个 Agent trajectory 被切成多个片段，再随机分到 Train/Test，可能产生什么风险？
7. Random Labels 实验中，训练准确率接近 100%、验证约 50%，说明了什么？
8. Validation Loss 抖动一次就立刻停止训练是否合理？实际 Early Stopping 为什么常用 patience？

答案

1. 典型 Overfitting 信号：训练仍在改善，但验证集已经恶化。
2. 高容量模型可以记忆训练样本甚至随机标签；训练成绩只描述见过的数据，不能替代独立评估。
3. $0.15 - 0.02 = 0.13$ 。但只有评价口径一致时才适合这样比较。
4. Validation。Test 应尽量保留到最终独立报告；若反复用 Test 调参，它就不再是独立测试。
5. 不能。这只能说明当前数据、训练预算和配置下，高容量模型出现了更强过拟合；还可能涉及数据量、Regularization、Early Stopping 等因素。
6. Trajectory-level leakage：Train/Test 共享高度相关上下文、任务模板或环境状态，导致测试成绩虚高。
7. 模型有能力记忆训练标签，但随机标签不存在稳定的输入到输出规律，因此无法泛化到独立数据。
8. 不一定。Validation 本身存在统计噪声；patience 允许短期波动，避免因一次偶然上升过早停止。