

第 42 讲实验设计

Train / Validation / Test 与 Data Leakage

一、实验目标

这组实验不追求模型性能，而是验证三个实验设计命题：

1. Train 用于拟合，Validation 用于模型选择，Test 应留到最后；
2. 反复尝试大量候选方案，即使没有真实能力，也可能把 Validation 最优值“挑高”；
3. 如果 split unit 错误，同一实体 / trajectory 跨 Train/Test，会制造虚假的高分。

二、实验 1：正确的模型选择流程

RQ1: 只用 Validation 选择多项式 degree，最后再看 Test，能否形成独立的最终评估？

数据: 600 个合成回归样本：

$$y = \sin(2\pi x) + \epsilon$$

Train/Val/Test = 360/120/120。

候选:

$$d \in \{1, 3, 5, 7, 9, 12, 15\}$$

控制变量: 同一数据 split；每个 degree 只在 Train 上拟合；选择标准只有 Validation MSE。

实际结果: Validation 选择 degree=9，Validation MSE=0.033263，最终 Test MSE=0.038365。

三、实验 2：Validation Overfitting / Selection Bias

RQ2: 如果所有候选模型都只是随机猜测，候选数量增大后，最佳 Validation Accuracy 会不会变得越来越漂亮？

设置: Validation 有 200 个随机二分类标签；Test 有 5000 个随机标签。每个候选模型都是随机预测，没有真实能力。

候选数量:

$$1, 10, 100, 1000, 5000$$

每种重复 80 次。

实际结果:




图 1: 候选模型的 Train/Validation/Test MSE。Test 曲线只用于课后解释，不参与选择。

候选数	Best Validation Acc	Selected Test Acc
1	0.4968	0.4994
10	0.5574	0.5007
100	0.5867	0.4994
1000	0.6138	0.4996
5000	0.6277	0.5014

结论：Validation 最优值可以因为“挑得多”而虚高，但独立 Test 仍显示没有真实能力。

四、实验 3: Group / Agent Trajectory Leakage

RQ3: 如果同一 group 的多个近重复记录被随机分散到 Train/Test，会怎样？

数据构造:

- 200 个 group；
- 每 group 6 条记录；
- 每 group 一个随机二分类 label；
- 同 group 内 feature 非常接近；
- group label 与 group center 没有可泛化规律。

模型: 1-NN。这个模型非常适合暴露“记住近重复样本”的问题。

对照:

1. 错误：row-level random split；
2. 正确：group-level split，完整 group 只属于一个集合。




图 2: 候选模型数量增加带来的 selection bias。

实际结果：

$Accuracy_{row} = 1.0000$

$Accuracy_{group} = 0.4472$

错误 row split 中，170 个 Test groups 全部与 Train 有 group overlap。

五、实验变量与验收标准

实验	自变量	关键因变量
实验 1	Polynomial degree	Train/Val/Test MSE
实验 2	候选模型数量	Best Val Acc、Selected Test Acc
实验 3	Split unit: row vs group	Test Accuracy、group overlap

验收标准：必须能够解释为什么实验 2、3 的高 Validation/Test 数字并不代表真实能力变强。

六、如何运行

```
python lesson42_train_val_test_leakage_experiment.py
```

输出：

- 第 42 讲 _ 实验实际输出.txt
- 4 张 PNG 实验图




图 3: 错误 row split 把“记住 group” 伪装成“泛化”。

七、科研结论边界

【常见误区 / 风险】

这些是教学用合成实验。它们证明的是“泄漏与选择偏差可以如何产生虚高指标”，不是在估计某个真实 LLM / Agent Benchmark 的具体污染程度。真实研究需要针对数据来源、重复结构、时间关系和任务层级单独设计 contamination audit。