

第 42 讲核心概念速查卡

Train / Validation / Test 与 Data Leakage

集合	主要职责	可以影响什么
Train	训练模型参数	Weight / Bias / Embedding 等 Parameter
Validation	模型选择、调参、Early Stopping	Hyperparameter、结构、checkpoint、Prompt / strategy
Test	最终独立评估	原则上不再反向影响开发决策

【原理】

核心边界：只要某个评估结果被用来决定“下一次怎么改模型”，这个数据集就已经参与开发。

Split Strategy

Random	样本近似独立同分布
Stratified	分类任务保持类别比例
Group	同一 user / patient / document / trajectory / task 不能跨集合
Time	用过去预测未来，严格按时间顺序
Domain	测试跨环境 / 跨机构 / 跨任务泛化

常见 Leakage

- Target Leakage: 输入包含未来才知道的答案信息；
- Preprocessing Leakage: 全数据 fit scaler / PCA / feature selection；
- Duplicate Leakage: 同一或近重复样本跨 split；
- Group Leakage: 同一实体 / trajectory 跨 split；
- Time Leakage: 未来信息进入过去训练；
- Benchmark Contamination: 测试题、答案、近重复进入训练 / RAG / Prompt 开发；
- Memory Leakage: Agent 测试时带着先前评测信息。

两个实验数字必须记住

随机候选模型数量增加时：

Best Val Acc : 0.497 $\rightarrow$ 0.628

但：

Test Acc $\approx$ 0.50

说明 Validation 也会被“选择过拟合”。

同一 group 多条记录：

Row Split Acc = 1.000

Group Split Acc = 0.447

说明 split unit 错了，测试分数可能完全失真。

科研检查清单

1. 独立单位是什么？
2. Split 在任何数据驱动 preprocessing 之前完成了吗？
3. Train/Val/Test 是否有 duplicate / group overlap？
4. Hyperparameter 和 checkpoint 是否只看 Validation？
5. Test 是否真的没有参与模型开发？
6. LLM/RAG/Agent Memory 是否含评测信息？
7. 是否保存 split IDs、seed、dataset version、去重规则？

【常见误区 / 风险】

Train Loss 低不等于 Generalization 好；Test 分数高也不自动等于没有 Leakage 或没有 Distribution Shift。