

第 42 讲练习题与答案

Train / Validation / Test 与 Data Leakage

练习题

1. 用一句话分别说明 Train、Validation、Test 的职责。
2. 研究者测试 6 个 Learning Rate，每次都看 Test Accuracy，然后选最高的那个报告。问题在哪里？
3. 数据集包含 500 个病人，每个病人 20 次随访记录。为什么不能直接随机切 10000 行？
4. Standardization 的 mean/std 应该在哪里计算？为什么？
5. 一个二分类问题真实没有规律。你尝试了 5000 个随机模型，挑出 Validation Accuracy 最高的一个。为什么它可能显著高于 50%？
6. Agent trajectory 有 100 个 episode，每个 episode 50 step。研究目标是泛化到新 episode。正确 split unit 应该是什么？
7. “Test 没有参与 backward，所以绝对没有 leakage。”这句话对吗？
8. Early Stopping 为什么属于 Validation 的职责？
9. Benchmark 原题没出现在训练集，但它的答案解析和近似改写大量出现，这是否仍可能构成 contamination？
10. 区分 Data Leakage 与 Distribution Shift。
11. 如果你需要比较 20 个 Agent communication protocol，应该如何避免因为反复选择而让最终结果过度适应 Validation？
12. 写出你未来 Agent Systems 实验在开始训练前至少应该保存的 5 项 split / data 元信息。

答案

1. Train 学 Parameter; Validation 做调参、结构与 checkpoint 选择; Test 在最终方案确定后评估独立泛化。
2. Test 已经参与了超参数选择, 实际承担了 Validation 角色; 最终 Test Accuracy 不再是严格独立估计。
3. 同一病人的记录高度相关。如果同一病人同时出现在 Train 和 Test, 模型可能识别病人特征而不是泛化到新病人。应该 patient-level split。
4. 只在 Train 上计算 mean/std, 然后用同一统计量 transform Validation/Test。否则评估集合的信息进入了 preprocessing。
5. 多重比较 / selection bias。即使每个模型都是随机猜测, 也会有人因为随机波动在 Validation 上看起来特别好。
6. 以完整 episode 为单位 split, 不能把一个 episode 的 step 分散到不同集合。
7. 不对。Test 结果只要影响了后续设计、Prompt、模型选择或阈值, 它就参与了开发。
8. Early Stopping 是根据未参与参数更新的数据判断何时停止训练、选择哪个 checkpoint, 本质是模型选择。
9. 是。近重复、答案、解析等都可能让模型间接见过评测内容。
10. Leakage 是不该知道的信息跨越了训练/评估边界; Distribution Shift 是未来数据分布本来就与训练分布不同。
11. 预先定义 Validation; 所有 protocol 只在 Validation 上选择; 冻结最终 protocol 后, 再用独立 Test 一次性评估。若搜索极大, 可再保留 second holdout / external test。
12. 示例: random seed、split IDs、group/task IDs、dataset version/hash、去重规则、preprocessing fit 范围、benchmark contamination 检查、RAG/Memory 数据来源。

【科研洞察】

最低验收标准: 看到任何模型分数时, 不先问“高不高”, 而先问“这个分数对应的数据是否真正独立? 独立单位是什么? 这个集合有没有参与模型开发?”