

第 43 讲实验设计

Regularization 与 Weight Decay 的泛化实验

一、实验问题

本实验不再问 “Weight Decay 的优化器公式是什么” (第 39 讲已经回答), 而是问:

1. 在小样本、高维、含噪声的任务中, 不加正则是否容易出现 Train 很好、Test 很差?
2. 适度 Weight Decay 是否可能降低 Validation/Test Error?
3. Weight Decay 是否会降低 Parameter Norm?
4. Weight Decay 太强是否会造成 Underfitting?

二、假设

- H1: $wd=0$ 时 Training MSE 最低, 但未必 Validation/Test 最好;
- H2: 中等 wd 会压缩噪声 Feature 的 Weight, 并改善 Val/Test;
- H3: wd 过大时真正有用的 Weight 也被过度收缩, Train/Val/Test 都恶化;
- H4: Parameter Norm 会随 wd 增强而总体下降, 但 Norm 与 Generalization 不会严格单调对应。

三、数据与控制变量

- Feature dimension: 100;
- 真正有用 Feature: 前 8 个;
- 噪声 Feature: 92 个;
- Train / Val / Test: 120 / 1000 / 1000;
- 模型: `nn.Linear(100,1,bias=False)`;
- Optimizer: SGD;
- LR: 0.02;
- Steps: 8000;
- 所有条件使用相同数据、相同模型初始化;
- 唯一主要自变量: `weight_decay`。

四、为什么实验使用 SGD，而不是 AdamW ？

本讲目标是建立 Regularization / Generalization 直觉。对于最基础 SGD，L2 penalty 与参数收缩有最清楚的代数联系：

$$\theta' = (1 - \eta\lambda)\theta - \eta g$$

所以能更干净地观察“限制 Parameter Scale”与 Generalization 的关系。

AdamW 的 decoupled 机制已在第 39 讲单独验证，本讲不重复混合两个问题。

五、自变量与因变量

Weight Decay Sweep：

$$0, 10^{-4}, 10^{-3}, 10^{-2}, 3 \times 10^{-2}, 10^{-1}, 3 \times 10^{-1}, 1$$

记录：

- Train MSE；
- Validation MSE；
- Test MSE（只做教学记录；超参数选择只看 Validation）；
- Parameter L2 Norm；
- 真正有用 Feature 的 mean $|w|$ ；
- 噪声 Feature 的 mean $|w|$ ；
- learned weight 与 true weight 的 cosine similarity。

六、结果

实验得到：

wd	Train	Val	Test	$\ w\ $
0	0.0475	1.9324	2.0636	3.4990
0.01	0.0495	1.5472	1.6492	3.3750
0.03	0.0591	1.2484	1.3223	3.2229
0.10	0.1080	1.1466	1.1897	2.9582
0.30	0.2872	1.5611	1.5713	2.6121
1.00	1.0500	2.8201	2.7907	2.0571

七、如何解释结果？

Validation 选择：

$$wd = 0.1$$

对应：

$$Val = 1.1466, \quad Test = 1.1897$$




图 1: Weight Decay Sweep 的 Train / Validation / Test MSE。




图 2: Weight Decay 增强后 Parameter Norm 总体下降。

wd=0 虽然 Train 最低，但 Test 较差，符合 Overfitting；wd=1.0 则连 Train 都明显变差，符合 Over-regularization / Underfitting。

噪声 Feature 平均绝对 Weight：

$$0.1073 \rightarrow 0.0715 \quad (wd : 0 \rightarrow 0.1)$$

与此同时 learned weight 与 true weight 的 cosine similarity：

$$0.9272 \rightarrow 0.9539$$

八、实验边界

【常见误区 / 风险】

这个实验只能支持“在这个受控高维回归任务中，适度 Weight Decay 改善了泛化”。不能推出：wd=0.1 对所有模型最优；Parameter Norm 越小越好；任何 LLM/Agent 微调都应该直接使用同样 wd。

真正科研中应进一步做：多 Seed、不同数据规模、不同模型容量、不同 Optimizer，以及跨 domain / task family 的独立 Evaluation。

九、运行方法

```
python lesson43_regularization_weight_decay_experiment.py
```

脚本会生成：

- 第 43 讲 _ 实验实际输出.txt
- figures/lesson43_weight_decay_sweep.png
- lesson43_parameter_norm.png
- lesson43_informative_vs_noise_weights.png
- lesson43_weight_profiles.png
- lesson43_regularized_objective.png