

第 43 讲核心概念速查卡

Regularization 与 Weight Decay

1. Regularization 的核心目标

牺牲一部分 Training Fit, 换取更好的 Generalization

典型现象: Train Loss 可能上升, 但 Validation/Test Error 下降。

2. L2 Regularization Objective

$$J(\theta) = L_{data}(\theta) + \frac{\lambda}{2} \|\theta\|_2^2$$

$$\nabla J = \nabla L_{data} + \lambda \theta$$

基础 SGD:

$$\theta_{t+1} = (1 - \eta\lambda)\theta_t - \eta\nabla L_{data}$$

3. 三种正则强度

正则强度	典型现象	风险
太弱	Train 极低, Val/Test 高	Overfitting
适度	Train 略差, Val/Test 更好	往往是目标区间
太强	Train/Val/Test 都差	Underfitting

4. 实验关键结果

wd	Train MSE	Test MSE	$\ w\ _2$
0	0.0475	2.0636	3.4990
0.1	0.1080	1.1897	2.9582
1.0	1.0500	2.7907	2.0571

5. 必须区分

- L2 Regularization: 把 penalty 加进 Objective;
- SGD Weight Decay: 与 L2 有直接代数对应;
- AdamW: decoupled weight decay, 第 39 讲已讲;
- Parameter Norm 小: 不等于泛化一定更好。

6. PyTorch

```
1 optimizer = torch.optim.AdamW(  
2     model.parameters(),  
3     lr=3e-4,  
4     weight_decay=0.1,  
5 )
```

【科研洞察】

Weight Decay 是 Hyperparameter: 用 Validation 选择, Test 留到最终确认。做 Ablation 时要控制 Optimizer、LR、Schedule、Steps/Tokens、Seed 与 Split。