

第 43 讲：练习题与答案

Regularization 与 Weight Decay

练习题

1. 用自己的话解释：为什么一个方法让 Training Loss 变高，却仍可能是“更好的模型”？
2. 若 $w = [3, 4]$, $\lambda = 0.2$, L2 penalty 定义为 $\frac{\lambda}{2}\|w\|^2$, 求 penalty。
3. 写出带 L2 Regularization 的 Objective: $J(\theta) = ?$ 。
4. 对最基础 SGD, 说明为什么 L2 Gradient 会产生参数收缩项 $(1 - \eta\lambda)\theta$ 。
5. 若 wd 从 0 增大到 0.1 后 Train MSE 从 0.05 升到 0.10, 但 Test MSE 从 2.0 降到 1.2, 这说明什么？
6. 若 wd 继续增大到 1.0 后 Train/Test 都明显变差, 这通常叫什么现象？
7. 为什么不能看到 Parameter Norm 更小, 就直接宣布模型 Generalization 更好？
8. 为什么 AdamW 中的 Weight Decay 不能简单等同于“在 Adam Gradient 里加 $\lambda\theta$ ”？
9. 设计一个 Weight Decay Ablation, 至少列出 5 个必须控制的变量。
10. Agent Systems 中如果训练任务只有少量 task family, 而模型容量很大, 你会怎样判断 Weight Decay 提升是否真的具有跨任务泛化价值？

参考答案

1. 因为目标不是把 Train 拟合到极致，而是降低未见数据上的误差。适度正则限制模型追随训练集噪声，因此 Train Loss 可能上升但 Val/Test 改善。
2. $\|w\|^2 = 25$ ，所以 $\text{penalty} = 0.2/2 \times 25 = 2.5$ 。
3. $J(\theta) = L_{data}(\theta) + \frac{\lambda}{2}\|\theta\|^2$ 。
4. L2 项 Gradient 为 $\lambda\theta$ ，代入 SGD: $\theta' = \theta - \eta(g + \lambda\theta) = (1 - \eta\lambda)\theta - \eta g$ 。
5. 说明原模型可能过拟合；适度 Weight Decay 牺牲了一部分训练拟合，换取更好的泛化。
6. 通常是 Over-regularization / Underfitting（过强正则导致欠拟合）。
7. 因为参数尺度受参数化方式、Normalization、模型结构等影响，而且过小参数也可能压制真正信号。必须由 Validation/Test 评估泛化。
8. 因为 Adam 会用一阶/二阶 Moment 自适应加工 Gradient；若把 decay 塞进 Gradient，它也被 Moment 机制处理。AdamW 将 decay 与 adaptive gradient update 解耦。
9. 示例：相同 Dataset/Split、相同初始化或多 Seed、相同 Optimizer、相同 LR/Schedule、相同 Steps/Tokens、相同 Batch、只改变 wd、Validation 选 wd、Test 最终确认。
10. 需要严格按 task family / environment / trajectory group 划分；在 unseen task family 上独立测试；固定训练预算与其他超参数；最好多 Seed，并同时报告 Train/Val/Test 与跨域结果。