

第 45 讲核心概念速查卡：为什么需要 Normalization

【原理】

最经典标准化：

$$\hat{x} = \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}}$$

目标不是“把所有数变一样”，而是把某一组数放到更可控的中心与尺度。

概念	核心理解
Mean μ	数值分布的中心位置
Variance σ^2	数字围绕均值的离散程度
Std σ	方差开平方，与原数据单位一致
Normalization	按某种 axis / group 计算统计量后重新缩放数值
ϵ	防除零、改善数值稳定
γ, β	标准化后可学习的 scale / shift

必须会回答的 6 个问题

1. 为什么 Feature Scale 会改变 Gradient Scale?
2. 为什么深层 Activation 的均值/标准差可能逐层漂移?
3. 为什么极大输入会让 Sigmoid / Tanh 更容易饱和?
4. Initialization 和 Normalization 有什么区别?
5. Normalization 是否改变 Tensor Shape? 通常不改变。
6. 看到 Normalization 时最先追问什么? **统计量沿哪些 Axis 计算。**

与 LLM 的连接

$$X : (B, T, D)$$

Transformer 中最常见的思考单位是 token hidden vector:

$$X[b, t, :] \in \mathbb{R}^D$$

LayerNorm / RMSNorm 会在第 47 讲详细学习。

【常见误区 / 风险】

Normalization $\neq$ Regularization; Normalization $\neq$ Data Preprocessing; `model.eval()` 对不同 Norm Layer 的影响也不完全相同。