

第 45 讲练习题与答案：为什么需要 Normalization

练习题

1. 给定 $x = [1, 3, 5, 7]$ ，求 mean、总体 variance、std，并写出标准化后的近似结果。
2. 如果三个特征分别典型尺度为 1, 100, 10000，为什么同一个全局 Learning Rate 可能很难同时适配三个 Weight?
3. Normalization 是否一定会改变 Shape? 举一个 (B, T, D) 的例子。
4. 为什么加入 ϵ ? 如果一组数全是 5，会发生什么?
5. Initialization 和 Normalization 的职责有什么区别?
6. 为什么输入尺度过大可能让 Sigmoid / Tanh 的 Gradient 变小?
7. 标准化后已经均值 0 方差 1，为什么还要 learnable γ, β ?
8. 看到论文写 “we apply normalization”，你至少还应该追问哪三个细节?
9. 数据预处理标准化时，为什么不能用 Test Set 一起计算 mean/std?
10. 在 Transformer hidden state $X : (32, 128, 768)$ 中，如果 LayerNorm 对最后一维处理，Shape 会变成什么?

答案

1. $\mu = 4$ 。总体方差 $(9 + 1 + 1 + 9)/4 = 5$, $\text{std} \approx 2.236$ 。标准化约为 $[-1.342, -0.447, 0.447, 1.342]$ 。
2. 因为简单线性层里 Weight Gradient 往往与输入尺度直接相关；特征尺度相差很大时，不同参数方向的有效坡度也相差很大，一个 LR 可能对某些方向太小、对另一些方向太大。
3. 通常不改变。例如 $(32, 128, 768)$ 经过 $\text{LayerNorm}(768)$ 仍为 $(32, 128, 768)$ 。
4. 防止 $\sigma^2 = 0$ 时除以 0，并改善数值稳定。全相同数据的方差就是 0。
5. Initialization 主要设计训练第 0 步的 Parameter 起点；Normalization 在 Forward 中持续控制中间表示尺度。
6. Sigmoid/Tanh 在 $|z|$ 很大时进入饱和区，局部导数接近 0，Chain Rule 中梯度容易被压小。
7. γ, β 让模型在稳定基准上重新学习需要的 scale 与 shift，避免表达能力被永久锁死。
8. 至少追问：沿哪些 axis 算统计量？train/eval 行为是否不同？是否有 learnable affine / running statistics？
9. 因为这样 Test 信息参与了建模流程，属于 preprocessing leakage，破坏独立评估。
10. 仍然是 $(32, 128, 768)$ 。Normalization 处理数值，不删除 token 或 hidden dimension。