

第 46 讲实验设计：BatchNorm 的统计轴、Batch 依赖与 Train/Eval

从“公式正确”到“机制可观察”的最小科研式实验

【实验总目标】

不是为了证明“BatchNorm 一定提升模型性能”，而是验证 7 个可重复的机制事实：手算一致性、 γ/β 、running statistics、batch dependence、small-batch noise、Batch Size=1 边界，以及 BatchNorm2d 的统计轴。

一、研究问题与假设

编号	研究问题	可验证假设
RQ1	手工公式是否和 PyTorch 一致？	最大误差只剩浮点舍入误差
RQ2	γ/β 是否真的恢复尺度自由度？	输出 mean/std 由 $\beta/ \gamma $ 控制
RQ3	running stats 如何变化？	它们缓慢跟踪多个 Batch，而非等于当前 Batch
RQ4	同样本是否依赖 Batch 同伴？	train 输出明显不同；eval 固定
RQ5	Batch Size 怎样影响统计噪声？	Batch 越小，mean/var 估计波动越大
RQ6	Batch Size=1 一定失败吗？	取决于每个 Channel 的有效统计元素数
RQ7	BN2d 的统计轴是什么？	对每个 Channel 沿 N, H, W 统计

二、实验环境与可复现性

- Python + NumPy + PyTorch + Matplotlib;
- 固定 `np.random.seed(46)`;
- 固定 `torch.manual_seed(46)`;
- 实验脚本一次性运行，所有关键数值写入 TXT;
- 所有图保存为 PNG，不依赖 Notebook 隐含状态;
- 当前验证环境为 CPU，但本实验不依赖 GPU。

三、实验 1：手工 BatchNorm vs PyTorch

输入：

$$X = \begin{bmatrix} 1 & 10 & 100 \\ 2 & 12 & 90 \\ 3 & 14 & 110 \\ 4 & 16 & 100 \end{bmatrix}$$

控制变量：`affine=False`、`track_running_stats=False`，只比较当前 Batch 公式。

验证指标：

$$\max |Y_{\text{manual}} - Y_{\text{torch}}|$$

实际结果：

$$2.38 \times 10^{-7}$$

标准化后的每个 Feature mean 约为 0，std 约为 1。




图 1: 实验 1: BatchNorm 前后每个 Feature 的尺度。

四、实验 2: γ/β 是否真的改变最终尺度？

设置：

$$\gamma = [2, 0.5, 1.5], \quad \beta = [1, -1, 0.2]$$

验证：

$$Y = \gamma \hat{X} + \beta$$

与 `BatchNorm1d(affine=True)` 是否一致。

实际最大误差：

$$4.92 \times 10^{-7}$$

输出 mean 约等于 β , std 约等于 $|\gamma|$ 。

五、实验 3: running statistics 的演化

连续输入 6 个均值逐步变化的 Batch, 记录：

- 当前 Batch Mean;
- 更新后的 running mean;
- 最终 running var;
- Eval 下固定 probe 的输出。




图 2: 实验 3: running mean 不等于当前 Batch Mean, 而是跨 Batch 累积的状态。

六、实验 4: 同一个样本是否依赖 Batch 同伴?

固定:

$$x = [1, 1, 1]$$

条件 A: 同伴集中在 0 附近; 条件 B: 同伴集中在 10 附近。只改变 Batch 同伴, 不改变目标样本。

实际训练态输出:

$$1.342 \quad \text{vs} \quad -1.704$$

最大差:

$$3.046$$

Eval 模式用固定 running stats, 重复输入的最大差:

$$0$$




图 3: 实验 4: BatchNorm 的训练态输出存在 batch coupling。

七、实验 5: Small Batch Statistics Noise

总体固定：

$$X \sim \mathcal{N}(3, 2^2)$$

对 $B = 2, 4, 8, 16, 32, 64, 128$ 各重复抽样 2000 次，记录 batch mean / variance 的跨试验标准差。

结果： $B = 2$ 时 $\text{std}(\text{batch mean})$ 约 1.398； $B = 128$ 时降到约 0.176。




图 4: 实验 5: Batch Size 增大后，统计量估计明显更稳定。

八、实验 6: Batch Size=1 的边界条件

条件 1:

$$X.shape = (1, 3)$$

训练态 BatchNorm1d(3) 报错: 每个 Channel 只有 1 个值。

条件 2:

$$X.shape = (1, 3, 4)$$

因为每个 Channel 可沿 N, L 收集 4 个值, 所以可以正常运行, 输出每个 Channel mean 约为 0。

科研含义: 不要机械写 “BN 不能 Batch Size=1”, 要先确认每个 Channel 的实际统计元素数和具体 BN 变体。

九、实验 7: BatchNorm2d 的统计轴

输入:

$$X.shape = (2, 2, 2, 2)$$

手工沿:

$$(N, H, W)$$

计算每个 Channel 的 mean / variance, 再与 BatchNorm2d(2) 对齐。

最大误差:

$$1.19 \times 10^{-7}$$

BatchNorm2d 的统计轴

Input shape: (N, C, H, W)

For each channel C independently:

collect values across N, H, W

compute mean / variance -> normalize -> gamma / beta

Statistics axes = (N, H, W); channel axis C is kept separate.

图 5: 实验 7: BatchNorm2d 的 Channel 保持独立, 统计轴是 N, H, W 。

十、结果解释边界

【不能从本实验推出什么】

- 不能推出 BatchNorm 一定提高所有任务的 Accuracy;
- 不能推出 Batch 越大模型一定泛化越好;
- 不能推出 Transformer 不可以技术上使用 BatchNorm;
- 不能把 toy experiment 的最优超参数直接搬到真实模型;
- 本实验验证的是机制, 而不是 SOTA 性能。

十一、建议的扩展实验

如果以后要把本讲变成更正式的小型研究实验，可以继续做：

1. 固定 Optimizer Step，只扫描 Batch Size，测 BN running stats 的方差；
2. 比较 BN / LayerNorm / RMSNorm 在同一 MLP/CNN 的训练稳定性；
3. 多随机种子报告 mean $\pm$ std；
4. 在 Distribution Shift 下比较 running stats 失配；
5. 多 GPU 下比较 per-device BN 与 SyncBatchNorm；
6. 记录 activation mean/std 和 gradient norm，分析机制而不只看最终 Accuracy。

【本实验的最低闭环】

你应能做到：提出“BatchNorm 是否依赖 Batch 同伴”这一机制问题；构造只改变同伴的控制实验；运行代码；得到 train 输出明显不同、eval 输出固定的结果；最后只得出与证据相符的局部结论。