

第 46 讲核心概念速查卡：BatchNorm

只用于复习；详细解释请看完整讲义

【1. 最核心公式】

对某个 Channel c :

$$\begin{aligned}\mu_{B,c} &= \frac{1}{m} \sum_i x_{i,c}, & \sigma_{B,c}^2 &= \frac{1}{m} \sum_i (x_{i,c} - \mu_{B,c})^2 \\ \hat{x}_{i,c} &= \frac{x_{i,c} - \mu_{B,c}}{\sqrt{\sigma_{B,c}^2 + \epsilon}}, & y_{i,c} &= \gamma_c \hat{x}_{i,c} + \beta_c\end{aligned}$$

γ, β 是可学习 Parameter; ϵ 用于数值稳定。

2. 一眼看懂 Axis

模块	输入 Shape	统计轴
BN1d	(N, C)	对每个 C 沿 N 统计
BN1d	(N, C, L)	对每个 C 沿 (N, L) 统计
BN2d	(N, C, H, W)	对每个 C 沿 (N, H, W) 统计

【一句话】

BatchNorm 的关键不是 “有没有 Normalization”，而是：哪些元素被放进同一个统计组里？

3. train() vs eval()

模式	用什么统计量归一化当前输入	是否更新 running stats
train()	当前 Mini-Batch mean / variance	是
eval()	running mean / running variance	否

【高频错误】

`model.eval()` 和 `torch.no_grad()` 不是一回事：前者改变 BatchNorm/Dropout 行为；后者关闭 Autograd 记录。

4. PyTorch 状态

- `weight` $\leftrightarrow \gamma$: Parameter;
- `bias` $\leftrightarrow \beta$: Parameter;
- `running_mean`: Buffer / running state;
- `running_var`: Buffer / running state;
- `num_batches_tracked`: 运行状态。

5. Small Batch 为什么危险？

- Batch mean / variance 估计更噪；
- 同一样本更容易因 Batch 同伴不同而改变输出；
- running statistics 更难稳定；
- 分布式训练必须关注 local batch，而不只是 global batch。

6. Batch Size = 1 的边界

$$(N, C) = (1, C)$$

训练时每个 Channel 只有一个值，BN1d 通常无法正常统计；但 (N, C, L) 中只要 $N \times L > 1$ ，仍可能有足够统计元素。

7. 与 CNN / LLM 的关系

方法	统计来源	Batch 依赖
BatchNorm	同 Channel 的 Batch / 空间元素	有
LayerNorm	单样本 / Token 的 Hidden Dimension	无
RMSNorm	单样本 / Token 的 Hidden Dimension RMS	无

【科研检查清单】

看一篇含 BatchNorm 的论文或代码，至少检查：

1. BN 的输入 Shape 与统计轴；
2. local batch size；
3. train/eval 是否切换正确；
4. running statistics 是否正确保存/恢复；
5. 多 GPU 是 per-device BN 还是 SyncBatchNorm；
6. Ablation 是否意外同时改变 Batch Size。