

第 46 讲练习题与答案: BatchNorm

一、练习题

1. 输入 $X.shape = (32, 128)$, 使用 `BatchNorm1d(128)`。均值和方差主要沿哪个轴统计? 一共得到多少个 mean?
2. 对某个 Feature, Batch 数值是 $[1, 3, 5, 7]$ 。手算 mean、biased variance, 并写出标准化公式 (可保留 ϵ)。
3. 为什么 BatchNorm 标准化之后还需要 γ 和 β ?
4. 判断正误: `model.eval()` 会自动关闭 Autograd。说明理由。
5. 同一个样本在训练模式下放入两个不同 Batch, BatchNorm 输出可能不同。为什么?
6. 输入 $X.shape = (8, 64, 16, 16)$, 使用 `BatchNorm2d(64)`。每个 Channel 的统计量沿哪些轴计算?
7. 为什么 Small Batch 会让 BatchNorm 更不稳定? 请用“统计量估计”的语言解释。
8. 一个模型的 `state_dict()` 中为什么需要保存 `running_mean` / `running_var`?
9. 对 $(N, C) = (1, 32)$ 的输入, 为什么训练态 BatchNorm1d 可能报错? 如果输入改成 $(1, 32, 10)$, 情况为什么可能不同?
10. 为什么现代 Transformer / LLM 更常用 LayerNorm / RMSNorm, 而不是 BatchNorm? 至少写出两个结构性原因。
11. 判断正误: BatchNorm 的 `momentum=0.1` 与 SGD 的 `momentum=0.9` 是同一种状态变量。说明理由。
12. 科研实验中, 把 Batch Size 从 64 改成 4, 同时模型中有 BatchNorm。为什么这不能简单解释成“只改变了优化噪声”?

二、参考答案

1. 沿 Batch 轴 $N = 32$ 统计；128 个 Channel 各自有一个 mean，所以得到 128 个 mean 和 128 个 variance。

2. $\mu = 4$ 。biased variance:

$$\sigma^2 = \frac{9 + 1 + 1 + 9}{4} = 5$$

标准化:

$$\hat{x}_i = \frac{x_i - 4}{\sqrt{5 + \epsilon}}$$

3. 因为纯标准化会暂时把尺度固定； γ/β 让网络重新学习适合任务的缩放与平移，保留表示自由度。

4. 错。eval() 改变 BatchNorm / Dropout 等模块的模式；Autograd 是否记录由 torch.no_grad()、requires_grad 等控制。

5. 训练态 BN 使用当前 Batch 的 mean / variance；Batch 同伴改变会改变共享统计量，因此同一样本的归一化值也会改变。

6. 对每个 C 独立，沿 $(N, H, W) = (8, 16, 16)$ 这些轴共同统计。

7. Batch 越小，从总体分布抽到的样本越少，batch mean / variance 的估计方差越大，所以归一化尺度更容易随 Batch 组成波动。

8. Evaluation 使用 running statistics。若不保存它们，恢复模型后即使可学习 Weight 相同，BN 的 Eval 输出仍可能不同。

9. (1, 32) 时每个 Channel 只有一个统计值；(1, 32, 10) 时 BN1d 可沿 N 和 L 合并统计，每个 Channel 有 10 个值。

10. 例如：LLM micro-batch 常很小/变化；自回归推理可能 batch=1；Token 希望独立按 hidden dimension 归一化；不同序列长度与 Padding 使 Batch 统计不自然；LayerNorm/RMSNorm 不依赖其他请求。

11. 错。BN momentum 是 running statistics 的更新系数；Optimizer momentum 是 Gradient 历史状态，二者对象和公式都不同。

12. 因为除了优化器 Gradient Noise 变了，BN 自己的 batch statistics 估计噪声也变了，甚至 train/eval gap 也可能变化，所以这是多个机制同时变化。

【自我验收】

如果你能不看答案解释第 5、6、8、10、12 题，说明你已经不仅会背 BatchNorm 公式，而开始真正理解它的统计轴、状态与实验影响。