

第 47 讲实验设计：LayerNorm、RMSNorm 与统计轴

1 实验目标

本实验不追求训练大模型，而是用最小可复现代码验证 8 个机制问题：

- 1. 手工 LayerNorm 是否与 PyTorch 对齐？
- 2. 手工 RMSNorm 是否与 PyTorch 对齐？
- 3. LayerNorm 与 RMSNorm 对整体平移的反应有何不同？
- 4. 同一样本更换 Batch 同伴后，BatchNorm / LayerNorm / RMSNorm 哪些会变化？
- 5. train/eval 是否改变 LayerNorm / RMSNorm 自身的数学输出？
- 6. 在 (B, T, D) 上，统计是否逐 Token 沿 D 进行？
- 7. 可学习参数的 Shape 和数量是什么？
- 8. Pre-Norm / Post-Norm 的 Shape 是否保持不变？

2 研究问题与假设

RQ	研究问题	预期 / 假设
RQ1	LayerNorm 手算和框架实现是否一致？	在同一 ϵ 下误差接近浮点误差。
RQ2	RMSNorm 是否保证均值为 0？	不保证；但输出 RMS 应接近 1。
RQ3	给 Hidden Vector 整体加常数会怎样？	LayerNorm 基本不变，RMSNorm 变化。
RQ4	同一 Token 换 Batch 同伴会怎样？	BatchNorm 变化，LN/RMSNorm 不变。
RQ5	train/eval 是否影响 LN/RMSNorm 自身？	不影响，因为没有 running statistics。
RQ6	(B, T, D) 上统计轴是什么？	每个 (B, T) 位置独立沿 D 统计。

3 变量与控制

自变量：Normalization 类型、是否整体平移、Batch 同伴、train/eval mode。

因变量：输出向量、均值、方差、RMS、同一样本输出差异。

控制变量：输入 Token、Hidden Dimension、 ϵ 、随机种子、affine 参数设置。

【常见误区 / 风险】

比较 Normalization 时，不要同时改变 Pre/Post-Norm、初始化、Learning Rate、模型深度等，否则很难归因。

4 实验步骤

实验 1：LayerNorm 手算

使用 $x = [1, 2, 3, 4]$ ，计算 μ, σ^2 、标准化结果；与 `nn.LayerNorm(4, elementwise_affine=False)` 对照。

实验 2: RMSNorm 手算

计算：

$$RMS = \sqrt{\text{mean}(x^2) + \epsilon}$$

并与 `nn.RMSNorm` 对照。

实验 3: 整体平移

比较 x 与 $x + 100$ 。记录两种 Norm 的最大绝对差异。

实验 4: Batch Dependency

把相同 target 放进两个统计分布极不相同的 Batch。分别比较 BatchNorm、LayerNorm、RMSNorm 的 target 输出。

实验 5: train/eval

对相同三维 Tensor，在 `train()` 与 `eval()` 下运行 LN/RMSNorm，比较最大差异。

实验 6: (B, T, D) 统计

构造 $(2, 3, 4)$ Hidden States，验证：

- LayerNorm 每个 Token 的 $\text{mean} \approx 0$ 、 $\text{variance} \approx 1$ ；
- RMSNorm 每个 Token 的 $\text{RMS} \approx 1$ ， mean 不要求为 0。

5 验收标准

- 手工 LN 与 PyTorch 最大误差 $< 10^{-5}$;
- 手工 RMSNorm 与 PyTorch 最大误差 $< 10^{-5}$;
- LN 对 +100 平移的最大差异接近 0;
- BatchNorm 同一样本换 Batch 后差异明显 > 0 ; LN/RMSNorm 差异接近 0;
- train/eval 下 LN/RMSNorm 自身输出差异接近 0;
- Shape 全程保持正确。

6 实际结果摘要

本次运行得到：

- LayerNorm 手工 vs PyTorch 最大误差：0;
- RMSNorm 手工 vs PyTorch 最大误差：0;
- LN 平移最大差异：0; RMSNorm 平移最大差异：约 0.6202;
- BatchNorm 同一样本换 Batch 最大差异：约 2.8209;
- LayerNorm / RMSNorm 同一样本换 Batch 最大差异：0;
- LN/RMSNorm train/eval 最大差异：0。

7 结果解释边界

【科研连接】

这些实验验证的是**机制属性**，不是性能优劣。不能仅凭这些结果得出“RMSNorm 比 LayerNorm 更好”或“LayerNorm 一定更稳定”。真实性能比较需要训练任务、多个随机种子、相同预算和公平 Ablation。

8 文件与运行

运行：

```
python lesson47_layernorm_rmsnorm_experiment.py
```

脚本会生成终端输出及 5 张实验图。

9 科研式实验记录建议

未来在 Transformer / LLM 实验中，如果替换 Norm，至少记录：

- Norm 类型与 ϵ ;
- affine 参数设置;
- Pre/Post-Norm 位置;

- model depth / hidden size;
- Optimizer、LR、Scheduler、Warmup;
- Training Tokens / Steps;
- Random Seeds;
- Gradient Norm / Activation RMS 等稳定性指标;
- Validation/Test 指标与置信区间。