

第 47 讲核心概念速查卡：LayerNorm 与 RMSNorm

一眼先问 Axis

- 对 Transformer Hidden States: $X.shape = (B, T, D)$ 。
- LayerNorm(D): 通常每个 (b, t) Token 自己沿 D 统计 mean / variance。
 - RMSNorm(D): 通常每个 (b, t) Token 自己沿 D 统计 RMS。
 - 输出 Shape 通常仍是 (B, T, D) 。

	LayerNorm	RMSNorm
统计量	μ, σ^2	$RMS = \sqrt{mean(x^2) + \epsilon}$
是否减均值	是	否
标准化	$(x - \mu) / \sqrt{\sigma^2 + \epsilon}$	$x / RMS(x)$
常见可学习参数	γ, β	γ
Batch 依赖	无	无
Running stats	无	无
train/eval 自身差异	无	无

【具体数字例子】

- $x = [1, 2, 3, 4]$:
- $LayerNorm(x) \approx [-1.3416, -0.4472, 0.4472, 1.3416]$
- 均值约 0、方差约 1。
- $RMSNorm(x) \approx [0.3651, 0.7303, 1.0954, 1.4606]$
- RMS 约 1，但均值约 0.9129。

【常见误区 / 风险】

- LN/RMSNorm 不等于“整个 Tensor 一起归一化”。
- RMSNorm 后均值不要求为 0。
- `eval()` 不会关闭 LN/RMSNorm。
- Pre-Norm/Post-Norm 是放置位置；LayerNorm/RMSNorm 是归一化公式。

Transformer / LLM 连接

【原理】

Pre-Norm:

$$Y = X + F(Norm(X))$$

Post-Norm:

$$Y = Norm(X + F(X))$$

【科研连接】

看论文时记录:

- Norm 类型: LayerNorm / RMSNorm / 其他;
- normalized shape / axis;
- ϵ ;
- affine 参数;
- Pre-Norm / Post-Norm;
- 是否同时改了 Residual Scaling、初始化或 Optimizer。

一句话心智模型

BatchNorm: 同一个 Channel 看一群样本。

LayerNorm: 一个 Token 看自己的 Hidden Features, 并做中心化 + 尺度化。

RMSNorm: 一个 Token 看自己的 Hidden Features, 只按 RMS 控制尺度。

最小 PyTorch

```
B, T, D = 2, 3, 4096
```

```
x = torch.randn(B, T, D)
```

```
ln = nn.LayerNorm(D)
```

```
rms = nn.RMSNorm(D)
```

```
y1 = ln(x)      # (B,T,D)
```

```
y2 = rms(x)     # (B,T,D)
```