

第 47 讲练习题与答案

A. 基础理解

1. 对 $X.shape = (4, 128, 768)$, `nn.LayerNorm(768)` 通常沿哪个维度计算统计量？一共独立做多少组归一化？
2. LayerNorm 为什么要减均值，而 RMSNorm 不减？二者最直接的数值差异是什么？
3. LayerNorm 是否依赖 Batch 中其他样本？RMSNorm 呢？
4. `model.eval()` 会让 LayerNorm 使用 running mean 吗？为什么？
5. LayerNorm 开启 affine 后， $D = 1024$ 时通常有多少个可学习参数？PyTorch RMSNorm 默认多少？

B. 数字与 Shape

6. 手算 $x = [1, 3]$ 的 LayerNorm (忽略 ϵ , 不使用 γ, β)。
7. 对 $x = [3, 4]$, 计算 RMS, 并写出 RMSNorm 结果 (忽略 ϵ)。
8. 若 $X.shape = (2, 5, 16)$, 经过 LayerNorm(16) 后 Shape 是什么？
9. 为什么 x 和 $x + 100$ 的 LayerNorm 结果相同，而 RMSNorm 通常不同？

C. 科研判断

10. 一篇论文把 LayerNorm 换成 RMSNorm, 同时把 Post-Norm 改成 Pre-Norm, 性能提高。能否直接得出 “RMSNorm 导致提升”？为什么？
11. 如果你要公平比较 LayerNorm 与 RMSNorm, 至少列出 5 个应该控制或记录的变量。
12. Agent 微调时 Batch Size 只有 1。LayerNorm 是否因为 Batch 太小就无法工作？解释原因。

参考答案

1. 沿最后的 768 维；独立组数 $4 \times 128 = 512$ 。
2. LayerNorm 做 mean-centering + scale；RMSNorm 只按 RMS scale。LN 标准化后均值约 0；RMSNorm 不要求均值 0。
3. 都不依赖 Batch 同伴（按常见沿最后 Hidden Dimension 的用法）。
4. 不会。LayerNorm 没有 BatchNorm 那样的 running statistics。
5. LayerNorm：1024 个 γ + 1024 个 $\beta = 2048$ ；PyTorch RMSNorm 默认只有 weight，1024 个。
6. $\mu = 2$ ，偏差 $[-1, 1]$ ，方差 1，因此输出 $[-1, 1]$ 。
7. $RMS = \sqrt{(9 + 16)/2} = \sqrt{12.5} \approx 3.5355$ ，输出约 $[0.8485, 1.1314]$ 。
8. (2, 5, 16)，Normalization 不改变 Shape。
9. 因为 LN 中输入和平移后的均值同时加 100， $x - \mu$ 不变；RMSNorm 不减均值，平方均值会改变。
10. 不能。两个变量同时改变，存在混杂。需要独立 Ablation 或 factorial design 才能拆因果贡献。
11. 至少包括：模型其余结构、Pre/Post-Norm 位置、初始化、Optimizer、LR/Schedule、 ϵ 、训练预算、随机种子、数据划分、Residual Scaling 等。
12. 可以。LayerNorm 的统计来自当前样本/Token 自己的 Hidden Dimension，而不是跨 Batch 估计。

【科研连接】

练习的重点不是算得快，而是每次都先明确：**Shape 是什么？统计轴是什么？哪些元素共同决定统计量？**