

第 48 讲练习题与答案：CNN 基础

练习题

1. 一批 RGB 图像 Shape 为 $(32, 3, 64, 64)$ ，四个数字分别代表什么？
2. 为什么一个 3×3 Kernel 覆盖一个 Patch 后只得到一个输出数字？
3. 输入为 7×7 ，Kernel=3，Stride=1，Padding=0，输出空间大小是多少？
4. 输入为 7×7 ，Kernel=3，Stride=2，Padding=1，输出空间大小是多少？
5. `Conv2d(3,16,kernel_size=3,bias=True)` 的 Weight / Bias Shape 与参数量是多少？
6. 为什么 Conv2d 的参数量通常不随输入 Height / Width 改变？
7. 输入 $(8, 3, 32, 32)$ 经过 `Conv2d(3,16,3,padding=1)` 后 Shape 是什么？
8. `MaxPool2d(2,2)` 输入 $(8, 16, 32, 32)$ 后典型输出 Shape 是什么？
9. “CNN 天然具有完全的平移不变性”是否正确？为什么？
10. 为什么深层 CNN 虽然单层只看局部，仍可以整合较大范围信息？
11. PyTorch Conv2d 严格数学上更接近 convolution 还是 cross-correlation？
12. CNN 与 Transformer 在“谁和谁交互”这件事上最核心的差异是什么？

答案与解析

1. $N = 32$ 张图, $C = 3$ 个 Channel, Height=64, Width=64。
2. Patch 与 Kernel 对应元素相乘后全部求和, 本质是局部 Dot Product, 所以得到一个标量。
3. $\lfloor (7-3)/1 \rfloor + 1 = 5$, 即 5×5 。
4. $\lfloor (7+2-3)/2 \rfloor + 1 = 4$, 即 4×4 。
5. Weight: (16,3,3,3); Bias: (16,); 参数量 $16 \times 3 \times 3 \times 3 + 16 = 448$ 。
6. 因为同一组 Kernel Weight 在所有空间位置共享。H/W 增大主要增加应用 Kernel 的次数, 不增加这组 Kernel 本身的参数数量。
7. (8,16,32,32)。Padding=1、Stride=1、Kernel=3 保持空间大小。
8. (8,16,16,16)。
9. 不正确。卷积本身更接近 translation equivariance: 输入移动, Feature Map 响应也移动。Pooling 等机制可带来一定位置容忍度, 但不等于完全不变。
10. 多层局部卷积会逐步扩大感受野; 例如 stride=1 的 3×3 Conv 堆叠时, 感受野可从 3×3 扩到 5×5 、 7×7 等。
11. 更接近 cross-correlation, 因为 PyTorch 默认不翻转 Kernel。
12. CNN 用固定局部 Kernel 在空间位置共享; Transformer Attention 会根据当前内容动态计算 Token/Patch 间关系, 长距离交互更直接。

最低验收

如果你能不看公式口述第 5、6、9、12 题, 并能自己算第 3、4、7、8 题, 本讲核心就已经掌握。