

第 50 讲核心概念速查卡：LSTM 与 GRU

1. LSTM 核心公式

$$i_t = \sigma(\cdots), \quad f_t = \sigma(\cdots), \quad g_t = \tanh(\cdots), \quad o_t = \sigma(\cdots)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t$$

$$h_t = o_t \odot \tanh(c_t)$$

Forget: 旧记忆保留多少; Input: 新信息写多少; Output: 向外暴露多少。

2. 为什么更利于长期 Gradient

直接 Cell-State 路径局部上:

$$\frac{\partial c_t}{\partial c_{t-1}} = f_t$$

多步近似直觉:

$$\frac{\partial c_T}{\partial c_0} \approx \prod_t f_t$$

f_t 长期接近 1 时, 梯度可比普通 RNN 中反复乘 Weight 与 $\tanh'$ 更容易保存。但这不是完整总导数, 也不代表无限记忆。

3. GRU 核心

PyTorch 风格:

$$r_t = \sigma(\cdots), \quad z_t = \sigma(\cdots)$$

$$n_t = \tanh(W_{in}x_t + b_{in} + r_t \odot (W_{hn}h_{t-1} + b_{hn}))$$

$$h_t = (1 - z_t) \odot n_t + z_t \odot h_{t-1}$$

GRU 没有独立 Cell State; 结构更紧凑。

4. PyTorch Shape

batch_first=True:

$$X : (B, T, D)$$

LSTM:

$$output : (B, T, H), \quad h_n : (L \times dir, B, H), \quad c_n : (L \times dir, B, H)$$

GRU:

$$output : (B, T, H), \quad h_n : (L \times dir, B, H)$$

5. 参数量（单层单向，PyTorch bias

$$RNN = HD + H^2 + 2H$$

$$GRU = 3(HD + H^2 + 2H)$$

$$LSTM = 4(HD + H^2 + 2H)$$

同 Hidden Size 下，GRU / LSTM 比普通 RNN 参数更多。

6. Stateful / Streaming

长序列可以拆成多个 chunk。只要把前一块最终状态传给后一块：

$$(h, c)_{chunk1} \rightarrow chunk2$$

LSTM / GRU 可以延续上下文。训练时若不想让 Gradient 无限追溯，可在边界对状态 detach()，形成 Truncated BPTT。

7. LSTM / GRU 仍然有什么限制？

- 仍然有 $state_t = f(x_t, state_{t-1})$ 的时间递推依赖；
- BPTT 仍然存在；
- 长期 Gradient 问题被缓解，但没有彻底消失；
- 时间轴训练并行性仍弱于 Transformer Self-Attention。

【常见误区 / 风险】

- Gate 不是二值开关，而是 0-1 的软比例。
- Cell State c_t 与 Hidden State h_t 不是同一个东西。
- GRU 的 Update Gate 在不同教材中可能用互补定义；先看公式，不要只背字母。
- Agent 的 External Memory 不等同于 LSTM 的 Cell State。

【科研连接】

下一讲：RNN / LSTM / GRU 与 Transformer 的真正结构差异——信息路径长度、并行性和 Self-Attention。