

第 50 讲练习题与答案: LSTM 与 GRU

练习题

1. 普通 RNN 主要维护哪一个状态? LSTM 额外引入了什么状态?
2. 在 LSTM 中, Forget Gate、Input Gate、Output Gate 分别控制什么?
3. 若 $c_{t-1} = 2$ 、 $f_t = 0.9$ 、 $i_t = 0.2$ 、 $g_t = 0.5$, 计算 c_t 。
4. 若连续 20 步只保留旧 Cell State, 且每步 $f = 0.95$, $c_0 = 1$, 则 c_{20} 是多少?
5. 为什么 f_t 接近 1 时, LSTM 的直接 Cell-State Gradient Path 更容易保存?
6. “ $\partial c_t / \partial c_{t-1} = f_t$ 就是 LSTM 的完整总梯度。”这句话为什么不严谨?
7. 对 `nn.LSTM(input_size=32, hidden_size=64, batch_first=True)`, 输入 Shape 为 (8, 20, 32), 单层单向时 output、 h_n 、 c_n 的 Shape 分别是什么?
8. 为什么相同 Hidden Size 下, LSTM 参数量约为普通 RNN 的 4 倍?
9. GRU 与 LSTM 最大的结构差异之一是什么?
10. 为什么 LSTM / GRU 即使缓解长期依赖, 也仍然难以像 Transformer 那样在时间轴上完全并行训练?
11. 分块处理长序列时, 为什么只传数值状态不一定等于让 Gradient 穿过所有历史?
12. 设计一个 RNN vs GRU vs LSTM 的公平 Ablation, 至少列出 5 个需要控制或报告的变量。

答案

1. 普通 RNN 主要维护 Hidden State h_t ; LSTM 额外维护 Cell State c_t 。
2. Forget: 旧 Cell State 保留多少; Input: 新 Candidate 写入多少; Output: Cell State 有多少暴露为 Hidden State。
3. $c_t = 0.9 \times 2 + 0.2 \times 0.5 = 1.9$ 。
4. $c_{20} = 0.95^{20} \approx 0.3585$ 。
5. 因为直接路径局部导数为 f_t ; 若许多 f_t 接近 1, 多步乘积衰减较慢。
6. Gate 本身也依赖 h_{t-1} , 而 h_{t-1} 又依赖更早状态; 完整计算图还有间接路径。 f_t 描述的是最重要的直接 Cell-State 路径。
7. output: (8, 20, 64); h_n : (1, 8, 64); c_n : (1, 8, 64)。
8. LSTM 每步需要 Input / Forget / Candidate / Output 四组 Linear 参数, PyTorch 中对应 $4H$ 行的 input-hidden / hidden-hidden 参数。
9. LSTM 有独立 Cell State, GRU 没有; GRU 通常用 Reset / Update Gate 直接更新 Hidden State。
10. 因为仍有 $state_t = f(x_t, state_{t-1})$, 第 t 步依赖第 $t-1$ 步状态。
11. 可以把 h, c 的数值传给下一块, 但通过 `detach()` 切断 Autograd 图, 所以数值上下文继续、Gradient 历史被截断。
12. 例如: 数据划分、Hidden Size 或参数预算、层数、Sequence Length、Optimizer、LR / Scheduler、Batch Size、训练 Steps / Tokens、Dropout、Gradient Clipping、随机种子、评估指标、计算预算。

自测标准

如果你能不用资料解释“为什么 LSTM 的 $c_t = f_t c_{t-1} + i_t g_t$ 比普通 RNN 的反复 $\tanh(W_h h)$ 更有利于长期 Gradient Flow”, 本讲最核心的原理就已经理解。