

第52讲实验设计：Embedding 查表、Shape、梯度与位置

实验目的：把“Embedding 是可学习向量”拆成可验证的数值命题，而不是只记 API。

实验问题与假设

实验	研究问题	预期
1	lookup 与 one-hot @ E 是否等价？	最大误差=0
2	(B,T) 经 Embedding 后 Shape 如何变？	变为 (B,T,D)
3	哪些 vocabulary rows 收到 Gradient？	只访问行非零；重复 Token 累加
4	padding_idx 是否收到梯度？	Padding row grad=0
5	纯 Token Embedding 是否知道位置？	同 Token 不同位置结果相同
6	Embedding row 能否被 SGD 学习？	访问行朝目标向量移动；未访问行不动
7	V×D 参数规模有多大？	按参数精度估算权重内存

控制变量

- 固定随机种子 `torch.manual_seed(52)`。
- 使用小矩阵与已知数值，便于手算。
- Shape / Gradient 实验避免混入复杂 Transformer。
- 训练实验只验证可学习性，不宣称获得真实语言语义。

主要依赖

Python、PyTorch、NumPy、Matplotlib。CPU 即可。

实验 1-3：查表等价、Shape、Gradient 行

实验1：Lookup vs One-Hot


定义 $V=5$ 、 $D=3$ 的已知矩阵 E ，选择 $\text{token_id}=3$ ，同时计算 $E[3]$ 与 $\text{one_hot}(3)@E$ 。指标：max absolute error。

实验2：Shape Flow

构造 $\text{token_ids.shape}=(2,4)$ ，使用 $\text{nn.Embedding}(5,3)$ 。记录输入与输出 Shape，并检查 $\text{token_ids}[0,1]=3$ 是否对应 $E[3]$ 。

实验3：Gradient Row

使用 $\text{IDs}=[1,3,1]$ ，令 $\text{loss}=\text{embedding}(\text{ids}).\text{sum}()$ 。理论上每次访问都给该行贡献全1向量，因此 Token 1 行应为2，Token3行为1，其余行0。



实验 4-5: Padding 与位置信息边界


实验4: padding_idx

创建 `nn.Embedding(..., padding_idx=0)`, 输入 `[0,2,0,4]`, Backward 后比较 `row0`、`row2`、`row4` 的梯度。

实验5: 同 Token 不同位置

序列 `[3,1,3,2]` 中位置0和2都是 Token 3。先比较纯 Token Embedding; 再人为加上示意 position vector, 观察差异。


这一实验只证明“Token lookup 本身不编码位置”。真实现代 LLM 可能使用 additive positional embedding, 也可能像 RoPE 一样在 Attention 的 Q/K 上注入位置信息。



实验 6-7：可学习性与资源估算

实验6：只训练部分 Vocabulary Rows

Embedding 初始化为0，训练 Token1 $\rightarrow [1, -1]$ ，Token3 $\rightarrow [-1, 1]$ 。记录 Loss 与最终 rows；检查从未出现的 Token2 是否保持0。



实验7：参数与内存

用 $V=50,000$ 、 $D=4096$ 计算 204,800,000 个参数；仅权重 fp16/bf16 约0.381 GiB，fp32约0.763 GiB。训练总显存还需另算 gradient、optimizer state、activation。

结果解释、有效性边界与复现清单

预期关键结果

lookup 与 one-hot @ E 误差 0。

输入 (2,4) 输出 (2,4,3)。

Gradient 非零行为只出现在访问过的 Token rows; 重复 Token 累加。

padding_idx row 梯度为0。

纯 Token Embedding 对同 ID 不区分位置。

训练后访问行接近目标向量，未访问行保持0。

不能从这些实验推出什么？

不能推出真实 LLM 的 Embedding 每一维有什么固定语义。

不能仅凭小玩具向量距离证明模型真正“理解”概念。

不能把位置示意向量等同于所有现代 LLM 的实际位置实现。

复现清单

记录 PyTorch 版本与设备。

保留随机种子。

保存完整实验输出 TXT。

确认图与输出数字一致。

如果修改 V、D、loss 或 optimizer，要在实验记录中明确。