

第52讲核心概念速查卡：Embedding

一句话：Embedding 是一个可训练参数矩阵 $E \in \mathbb{R}^{(V \times D)}$ ，整数 Token ID 通过查行变成 D 维浮点向量。

概念	最小记忆
Vocab Size V	Embedding Matrix 的行数
Embedding Dim D	每个 Token 的向量长度
weight.shape	(V,D)
输入 Shape	例如 (B,T)，dtype 通常是整数 Long
输出 Shape	(B,T,D)
核心操作	$E[\text{token_id}]$ ：按索引查行
参数量	$V \times D$
Backward	被访问行收到梯度；重复 Token 梯度累加

核心公式 / 等价关系

$$\text{lookup}(\text{id}) = E[\text{id}]$$

$$\text{one_hot}(\text{id}) @ E = E[\text{id}]$$

Embedding vs Linear

Embedding	Linear
离散整数 ID $\rightarrow$ 向量	连续浮点向量 $\rightarrow$ 新向量
查表	矩阵乘法 + Bias
只访问索引行	通常所有 Weight 参与

LLM 连接与常见误区

$(B, T) \rightarrow \text{Token Embedding} \rightarrow (B, T, D)$

同一个 Token 的纯 Token Embedding 在不同位置相同；位置信息由 additive position、RoPE 等额外机制引入。

Token Embedding 不等于 Transformer 后的 Contextual Hidden State。

padding_idx 可让 Padding Row 不接受普通 lookup 路径的梯度。

输入 Embedding 与输出 LM Head 可能 weight tying，但不是所有模型都必须如此。

看到代码时立刻问

```
emb = nn.Embedding(V, D, padding_idx=0)
x = emb(token_ids)
# emb.weight.shape == (V, D)
# token_ids.shape == (B, T)
# x.shape == (B, T, D)
```

自检

Token ID 是数值大小还是索引？

V 和 D 分别控制什么？

为什么只更新部分行？

位置和上下文分别在哪一步进入？