

第52讲练习题：Embedding

建议先独立完成，再看第 2 页答案。

基础题

1. 一个词表 $V=10,000$ ，Embedding Dimension $D=512$ 。Embedding Matrix 的 Shape 和参数量分别是多少？
2. Token IDs 的 Shape 是 $(8,128)$ ，经过 `nn.Embedding(50000,768)` 后输出 Shape 是什么？
3. 给定 $E=[[1,0],[0,1],[2,-1]]$ ，Token ID=2，lookup 输出是什么？
4. 写出 Token ID=1 的 one-hot，并验证 `one-hot @ E` 与 lookup 是否一致。
5. 为什么不能简单把 Token ID 1532 当成连续标量特征输入 `Linear(1,D)`？

理解题

6. 序列 $[1,3,1]$ 中 Token 1 出现两次。如果 Loss 对三个 Embedding 输出的上游梯度都为 $[1,1]$ ， $E[1]$ 的梯度是多少？
7. 同一个 Token 在位置 2 和位置 20 的纯 Token Embedding 是否一定不同？为什么？
8. Token Embedding 和 Contextual Hidden State 有什么区别？
9. `padding_idx=0` 时，普通 lookup/backward 路径下第 0 行 Gradient 有什么特点？
10. 一个模型使用 `vocab=50,000`、`D=4096`。仅输入 Embedding 权重使用 `bf16/fp16`，大约需要多少 GiB？不要求精确到小数后很多位。

第52讲练习题答案

1.

Shape=(10,000,512)。参数量=10,000×512=5,120,000。

2.

输入 (8,128)，每个 ID 追加一个 768 维向量，因此输出 (8,128,768)。

3.

Token ID=2 查第 2 行（从 0 开始）：[2,-1]。

4.

Token ID=1 的 one-hot=[0,1,0]；[0,1,0]@E=[0,1]，等于 E[1]。

5.

ID 首先是离散索引，不具有连续大小/距离语义。直接作为实数输入会错误引入“编号大小关系”。

6.

同一 Parameter Row 的两条使用路径会累加：E[1].grad=[2,2]。

7.

纯 Token Embedding 查同一行，因此相同。位置差异需要位置编码或 RoPE 等额外机制。

8.

Token Embedding 是上下文之前由 Token ID 查表得到的基础向量；Contextual Hidden State 已经过 Transformer，与周围 Token、位置等有关。

9.

padding_idx 对应行在普通 nn.Embedding backward 中保持零梯度。

10.

50,000×4096=204,800,000 个参数。每个 fp16/bf16 约 2 bytes，因此约 409,600,000 bytes，约 0.381 GiB。