

第 53 讲 实验设计

Q/K/V Projection：数值、Shape、Token 独立性、Fused 实现与梯度

实验总问题	Q/K/V 是否真的只是三套 Linear Projection？它们的 Shape、PyTorch 实现、Token 依赖关系、融合实现和 Backward 是否与我们的理论完全一致？
-------	---

实验环境

Python 3、NumPy、PyTorch。无需 GPU。全部矩阵很小，目的是验证机制，不是做性能 Benchmark。

控制原则


固定输入 X 与 W_Q/W_K/W_V；NumPy 与 PyTorch

使用完全相同参数；涉及对照时只改变一个变量；所有关键结果保存到 TXT。

实验 1-3：数值与 PyTorch 对齐

实验	操作	预期观察
1	NumPy 计算 $Q=XW_Q, K=XW_K, V=XW_V$	得到三个 (3,3) 矩阵
2	手算 Token2 的 q_2	与矩阵乘法完全一致
3	把相同 Weight 复制进 nn.Linear	NumPy/PyTorch 最大误差为 0 或浮点误差


Q / K / V = same X, different learnable projections



实验 4-6：Shape、Token 独立性与 Fused QKV

实验	变量	关键验证
4	X3:(2,3,4)	三套 Projection -> (2,3,3)
5	只修改 Token1	只对应 Q/K/V 的第1行改变；其他 Token 不变
6	Linear(4,9) + split	与三套 Linear(4,3) 完全等价
科研意义		这组实验把“QKV Projection”和“Attention Token mixing”分离开。以后做机制 Ablation 时，必须清楚你改的是 feature projection，还是 token interaction。

Projection is token-wise: no token mixing yet




实验 7-8：QK^T Shape 预览与 Backward

实验 7 只计算：

$$\text{Scores} = Q @ K^T$$

验证 Shape 从 (T,d_k) 和 (d_k,T) 变成 (T,T)，但本讲不继续 Softmax。



实验 8 定义一个人为标量 Loss，让 Q/K/V 三条分支都参与，再执行 backward。预期 W_Q/W_K/W_V 都有各自 Gradient，X.grad 则累加三条支路的贡献。

实验 9：参数量与结论边界

对 $D_{\text{model}}=768$ ，验证三套 $D \rightarrow D$ Projection：

$$\text{weights} = 3 * 768^2 = 1,769,472$$

$$\text{with bias} = 1,771,776$$

同时验证一个 $\text{Linear}(768, 2304)$ 与三套 $\text{Linear}(768, 768)$ 具有相同总参数量。

不要过度解释

本实验只验证数学等价、Shape 与梯度路径。它不证明真实 LLM 中 fused QKV 一定更快，也不比较不同硬件 kernel 性能；性能结论必须用严格 Benchmark 单独验证。

实验输出验收

运行代码后应看到：NumPy/PyTorch 误差为 0 或极小；改变单个 Token 只改变对应投影行；fused QKV 与分立结果一致； QK^T 为 (3,3)；三套 Weight 梯度均非零。