

第 53 讲 练习题与答案

建议先独立作答，再看答案。重点不是背变量名，而是练 Shape 与计算链。

1. $X.shape=(4,10,64)$, $W_Q.shape=(64,32)$ 。Q.shape 是什么？
2. 为什么 $Q=XW_Q$ 不会让 Token 3 直接读取 Token 1？
3. $nn.Linear(64,32)$ 的 $weight.shape$ 为什么是 $(32,64)$ ？
4. 如果 $W_Q=W_K=W_V$ 且 bias 相同，会发生什么？
5. $D_{model}=512$ ，三套 $512 \rightarrow 512$ 的无 bias QKV Projection 有多少 Weight 参数？
6. $X:(B,T,D)$, $Q/K:(B,T,d_k)$ 。 QK^T 的 Shape 是什么？
7. 为什么 fused $Linear(D,3D)$ 与三套 $Linear(D,D)$ 可以数学等价？
8. 判断：Q/K/V Projection 已经完成 Token mixing。对还是错？为什么？
9. 一个 Token 在两个位置拥有完全相同的 X，且没有任何位置机制时，它们经过同一 W_Q 后 Query 是否相同？
10. 如果某篇论文改的是 W_Q 的低秩增量，而 Attention score 公式不变，它主要修改了哪一阶段？

参考答案

1. (4,10,32)。B 和 T 保留，只改变最后一个 feature dimension。
2. 普通 Linear 对每个 Token 向量独立作用。Token-to-token interaction 要等 QK^T 等后续 Attention 运算。
3. PyTorch 每个输出 feature 对应 weight 的一行，因此保存为 (out_features,in_features)，前向使用 $X @ \text{weight.T}$ 。
4. 在相同输入下 $Q=K=V$ ，模型失去三种角色独立投影的自由度。
5. $3 \times 512 \times 512 = 786,432$ 。
6. 若忽略 head 维，则 (B,T,T)。
7. 把 $W_Q/W_K/W_V$ 沿输出维拼成一个大矩阵，一次 matmul 后再沿最后一维切开即可。
8. 错。Projection 只重组每个 Token 自己的特征。
9. 相同。若 X 完全一样且 W_Q 相同，线性映射结果也一样。位置差异必须由位置机制或上下文先进入 $X/Q/K$ 。
10. 修改 Q Projection 阶段，即 Query 表示如何从 hidden state 产生；这会进一步改变后续匹配 score。

进阶 Shape 题

设 $B=2$, $T=5$, $D_{\text{model}}=12$, $\text{num_heads}=3$, $d_{\text{head}}=4$ 。标准 Q/K/V 总投影均输出 12 维。

(1) Q 投影后 Shape? (2) 拆 Head 后常见 Shape? (3) 单个 Head 的 QK^T Shape? (4) 全部 Head 的 score Shape?

答案	(1) (2,5,12); (2) 常见为 (2,3,5,4); (3) 每个 Head 为 (5,5); (4) 常见为 (2,3,5,5)。
----	--

这道题只是为第 55 讲 Multi-Head 做 Shape 预热，本讲不要求进一步推导 Multi-Head。