

第 54 讲 核心概念速查卡

Scaled Dot-Product Attention

Scores = Q @ K^T	
Scaled = Scores / sqrt(d_k)	
Masked = Scaled + Mask	
A = Softmax(Masked, dim=Key)	
Output = A @ V	
对象	典型 Shape
Q/K/V	(B,H,T,d)
Scores / Weights	(B,H,T,T)
Output	(B,H,T,d_v)
必须记住	Softmax 沿 Key 维；每个 Query 得到一行对 Key 的权重。QKV Projection 不混 Token, A@V 才发生真正聚合。

Mask / Scaling / Debug 快查

问题	检查点
Softmax 太尖	score 是否漏除 sqrt(d_k)
未来 Token 权重非零	causal mask 是否在 softmax 前生效
每行权重和不为1	softmax dim 或 mask 顺序是否错误
QK^T Shape 错	K 是否 transpose(-2,-1)
Output Shape 错	Weights(...,T,T) 是否乘 V:(...,T,d_v)
Causal: future score -> -inf -> softmax weight 0	
$\text{Var}(q \cdot k) \sim d_k \Rightarrow \text{Std}(q \cdot k) \sim \sqrt{d_k}$	