

第 54 讲 练习题与答案

先独立完成。重点是每一步的 Shape 与语义。

1. Q,K 的 Shape 都是 (5,8)。QK^T 的 Shape 是什么？
2. 若 d_k=64, scale factor 是多少？
3. 为什么 d_k 变大时不缩放会让 Softmax 更容易饱和？
4. Causal Mask 中, 第 4 个 Token 可以看到哪些位置？
5. 为什么 Mask 常设置成 -inf, 而不是 0？
6. Attention Weight 一行是 [0.25,0.75], V1=[2,0], V2=[0,4], 输出是什么？
7. 判断：QKV Projection 已经完成 token mixing。
8. 判断：Causal LM 训练必须像生成一样逐 Token 执行。
9. Batch/Head 情况下 Q:(2,4,10,16), K 同 Shape。score Shape？
10. 为什么 Attention Weight 不能机械解释为最终预测的因果重要性？

参考答案

1. (5,5)。
2. $\sqrt{64}=8$ ，因此 score 除以 8。
3. Dot Product 的标准差近似按 $\sqrt{d_k}$ 增大，Softmax 对大差距指数放大，容易变得近 one-hot。
4. 位置 1-4，不能看未来。
5. softmax 前设为 $-\infty$ 后 $\exp(-\infty)=0$ ，保证该位置权重严格为 0；若设 0，仍可能分到非零权重。
6. $0.25[2,0]+0.75[0,4]=[0.5,3.0]$ 。
7. 错。Projection 仍逐 Token； $A@V$ 才聚合多个 Token。
8. 错。训练可一次计算整张 masked attention matrix；生成因为未来 Token 尚不存在而仍逐步进行。
9. (2,4,10,10)。
10. 最终网络还有多 Head、多层、残差、MLP 等路径；Attention Weight 只描述当前局部聚合比例。

手算题

设 $q=[1,0]$, $k_1=[1,0]$, $k_2=[0,1]$, $v_1=[2,0]$, $v_2=[0,4]$, $d_k=2$ 。

(1) 计算 raw score ; (2) 除以 $\sqrt{2}$; (3) 做 Softmax ; (4) 计算输出。

答案提示

raw=[1,0] ; scaled $\approx$ [0.707,0] ; softmax $\approx$ [0.670,0.330] ; output $\approx$ [1.340,1.320]。