

第 55 讲 实验设计

Multi-Head : reshape、transpose、Mask Broadcasting、Concat、W_O 与 PyTorch 对齐

实验总目标	证明 Multi-Head 并不是神秘的新运算，而是“先分 Head -> 每个 Head 独立做上一讲的 Attention -> concat -> output projection”。
-------	--


实验边界

实验使用极小 $D=4$ 、 $H=2$ 便于手算。为了突出 Head splitting, Q/K/V 先采用 identity projection；真实模型中 Q/K/V Projection 会先混合全部输入特征。

实验 1-4：Head 拆分、独立 Pattern、Concat、W_O

实验	验证
1	$(B,T,D) \rightarrow (B,T,H,d) \rightarrow (B,H,T,d)$
2	两个 Head 得到不同 causal attention weights
3	transpose 回来再 concat, 恢复 (B,T,D)
4	固定 W_O , 验证最终输出仍为 (B,T,D)

reshape -> transpose -> independent attention per head



实验 5-7：框架对齐与 Mask Broadcasting

先用 `F.scaled\_dot\_product\_attention` 对齐每个 Head 的手写结果，再配置 `nn.MultiheadAttention` 的 `in\_proj\_weight` / `out\_proj`，使其与手写完整 MHA 对齐。

随后构造 scores:(2,2,4,4)，组合：

causal:(4,4)
padding:(2,1,1,4)


验证广播后第二条样本最后一个 PAD Key 的最大 Attention Weight 为 0。

Mask 质检

科研代码必须对一个极小 toy input 显式打印 Attention Weight，确认未来位置/PAD 是否真为 0。只看 Shape 正确不够。

实验 8-10：Head Count、参数量与独立性

固定 $D=64$ ，比较 $H=1/2/4/8$ ：标准 `nn.MultiheadAttention` Parameter Count 应保持不变；再对 $D=768$ 检查多个 Head 数，验证总参数量仍一致。



最后只修改 Head1 的输出，确认 Head2 本身不变，但 `concat + W_O` 后的最终输出会改变。

结论边界

参数量不变不等于运行时内存不变。Score tensor 具有 (B, H, T, T) 逻辑 Shape； H 增大会增加独立 score maps 数量。

实验验收

运行脚本后至少应看到：

- 1) Head1/Head2 的 Attention Weight 不同；
- 2) manual 与 F.scaled_dot_product_attention 最大误差接近 0；
- 3) manual 与 nn.MultiheadAttention 最大误差接近 0；
- 4) PAD key 最大权重为 0；
- 5) D 固定时不同 H 的 Parameter Count 相同；
- 6) 只改 Head1 不会直接改 Head2，但会通过 W_O 改最终输出。