

# 第 55 讲 核心概念速查卡

## Mask 与 Multi-Head Attention

| D_model = H * d_head                  |                                                                                  |
|---------------------------------------|----------------------------------------------------------------------------------|
| (B,T,D) -> (B,T,H,d) -> (B,H,T,d)     |                                                                                  |
| Scores: (B,H,T,T)                     |                                                                                  |
| HeadOut: (B,H,T,d)                    |                                                                                  |
| Concat -> (B,T,D) -> @ W_O -> (B,T,D) |                                                                                  |
| 对象                                    | 典型 Shape                                                                         |
| Q/K/V                                 | (B,H,T,d_head)                                                                   |
| Causal Mask                           | (T,T), broadcast                                                                 |
| Padding Mask                          | 常见逻辑 (B,1,1,T)                                                                   |
| Weights                               | (B,H,T,T)                                                                        |
| Concat Output                         | (B,T,D_model)                                                                    |
| 最重要                                   | Head 拆 Feature, 不拆 Token ; Scaling 用 sqrt(d_head) ; W_O 负责 concat 后重新混合 Head 信息。 |

# PyTorch / Debug 快查

```
mha = nn.MultiheadAttention(D, H, batch_first=True)
out, w = mha(x, x, x, attn_mask=mask,
              need_weights=True,
              average_attn_weights=False)
```

| 问题             | 先检查                        |
|----------------|----------------------------|
| embed_dim 报错   | D % H 是否等于 0               |
| score Shape 错  | K 是否 transpose(-2,-1)      |
| 未来权重非零         | causal mask 语义/广播是否正确      |
| PAD 被关注        | padding mask 是否真正作用到 Key 维 |
| concat Shape 错 | 是否先 transpose 回 (B,T,H,d)  |
| 结果与框架不一致       | mask、bias、W_O、scale 是否一致   |