

第 55 讲 练习题与答案

重点练 Shape、Mask 与 Head 语义。

1. $D_{\text{model}}=768$, $\text{num_heads}=12$, d_{head} 是多少？
2. $X.\text{shape}=(4,128,768)$ 。拆 Head 后 Q 的常见 Shape？
3. Head 拆的是 sequence length 还是 feature dimension？
4. $Q/K/V=(B,H,T,d)$, score Shape 是什么？
5. 为什么 scale 用 $\text{sqrt}(d_{\text{head}})$ ？
6. 8 个 Head 的输出各为 $(B,T,64)$, concat 后 Shape？
7. W_O 常见 Shape 是什么？为什么需要它？
8. Causal Mask 与 Padding Mask 各解决什么问题？
9. D_{model} 固定时，从 8 Head 改成 16 Head，标准 QKV/O 参数量一定翻倍吗？
10. 为什么看到某个 Head 的 Heatmap 很有规律，还不能直接说它“因果负责”某功能？

参考答案

1. $768/12=64$ 。
2. (4,12,128,64)。
3. Feature Dimension。所有 Head 仍看到完整 Token 序列。
4. (B,H,T,T)。
5. 每个 Head 的 Dot Product 维度是 d_{head} ，score 标准差近似随 $\sqrt{d_{\text{head}}}$ 增大。
6. (B,T,512)。
7. 常见 (D,D)。它把多个 Head concat 后重新线性混合，并保持 Residual 所需的 D_{model} 。
8. Causal Mask 阻止看未来；Padding Mask 阻止把 PAD 当真实 Key。
9. 不会。在标准 MHA、D 固定时，大矩阵总尺寸近似不变；主要是 d_{head} 变小。
10. 最终输出还有其他 Head、层、Residual、MLP；Heatmap 是局部相关证据，不等于因果机制证明。

Shape 综合题

设 $B=2$, $T=6$, $D=12$, $H=3$ 。

(1) d_head ? (2) Q 投影后总 Shape? (3) 拆 Head 后? (4) Score? (5) Head Output? (6) Concat? (7) W_O 后?

答案

$d_head=4$; Q total=(2,6,12); split=(2,3,6,4); score=(2,3,6,6); head out=(2,3,6,4); concat=(2,6,12); W_O 后仍为 (2,6,12)。