

第 56 讲 实验设计

Transformer Block : Shape、Token Mixing、Residual、Pre/Post-Norm 与参数量

实验总目标	把一个 Transformer Block 拆成可以逐步验证的子机制，避免把整个 Block 当成一个无法检查的黑盒。
-------	---


环境

Python 3 + PyTorch, CPU 即可。实验使用极小 `d_model=8`, 便于打印 Shape 与数值。

实验 1-3：Block Shape 与模块分工

实验	验证
1	Pre-Norm Block 手工逐步 forward 与封装 nn.Module 完全一致
2	只改 Token1：MLP 只改变 Token1 自己的输出
3	只改 Token1：Causal Attention 可以影响后续 Token

Pre-Norm Transformer Block: outside shape stays (B,T,D)




实验 4-6：Residual 与 Norm 结构

实验 4 把 Attention/MLP 参数清零：Pre-Norm 应严格返回 x ；Post-Norm 仍输出 $\text{Norm}(x)$ 。

实验 5 使用 30 层 toy nonlinearity，对比有无 residual 的 input gradient norm，只作为 identity path 的机制演示。

实验 6 用完全相同子层 Weight 对比 Pre/Post-Norm 的单次 toy gradient，明确标注“该数值不是一般定理”。




科学边界

Toy gradient 只验证结构可以造成不同传播条件。不能用一次随机数值证明 Pre-Norm 在所有模型/任务上必然更优。

实验 7-8：参数量与 train/eval

实验 7 用 $D=768$ 、 $D_{ff}=3072$ 、 $H=12$ 统计 MHA / MLP / $2\times\text{LayerNorm}$ 参数量，验证 MLP 往往是大头。



实验 8 使用 $\text{dropout}=0.5$ ：train 模式两次 forward 不同，eval 模式两次 forward 完全一致；同时强调 LayerNorm 自身 train/eval 行为不切换。

验收清单

运行脚本后应看到：

- 1) 手工 Pre-Norm forward 与 Module 输出最大误差为 0；
- 2) MLP 只改变被修改的 Token；
- 3) Attention 可以把早期 Token 变化传播到后续 Token；
- 4) Pre-Norm 零子层输出等于原 x ；Post-Norm 不等于；
- 5) Residual toy gradient 比无 Residual 更容易保留；
- 6) 典型配置下 MLP 参数量大于 MHA；
- 7) Dropout 导致 train 随机、eval 确定。