

第 56 讲 核心概念速查卡

$\text{Transformer Block} = \text{Attention} + \text{MLP} + \text{Residual} + \text{Norm}$

Pre-Norm Attention: $X1 = X + \text{MHA}(\text{Norm1}(X))$	
Pre-Norm MLP: $Y = X1 + \text{MLP}(\text{Norm2}(X1))$	
MLP: $D \rightarrow D_{\text{ff}} \rightarrow D$	
模块	负责什么
MHA	Token mixing
MLP	每个 Token 内部 feature transformation
Residual	identity path / add update
LayerNorm/RMSNorm	hidden scale control
Shape	Block 外部通常一直是 (B,T,D)。Attention 内部拆 Head，MLP 内部扩 D_{ff} ，但 Add 前必须回到 D。

Pre / Post Norm 与参数量快查

Pre: $y = x + F(\text{Norm}(x))$	
Post: $y = \text{Norm}(x + F(x))$	
MHA weight params $\approx 4D^2$	
MLP weight params $\approx 2D \cdot D_{\text{ff}}$	
if $D_{\text{ff}} \approx 4D$, $\text{MLP} \approx 8D^2$	
Debug	先检查
Residual 加法报错	两支 Shape 是否一致
Block 只影响单 Token	Attention mask / QKV 是否异常
eval 输出随机	是否忘了 model.eval(), Dropout 是否仍开
深层训练不稳	Norm 位置、LR、初始化、Residual 是否合理