

第 56 讲 练习题与答案

重点练 Block 结构、Shape、Residual 与 Pre/Post-Norm。

1. 为什么标准 Transformer MLP 不负责 Token mixing ?
2. $X.shape=(2,128,768)$, MLP 的 $D_{ff}=3072$ 。fc1/fc2 各输出什么 Shape ?
3. 为什么 Residual Add 要求子层最终回到 D_{model} ?
4. 写出 Pre-Norm Attention 子层公式。
5. 写出 Post-Norm Attention 子层公式。
6. 如果 Pre-Norm 中 $F(x)=0$, 输出是什么 ? Post-Norm 呢 ?
7. $D=768$, $D_{ff}=3072$, 经典两层 MLP 无 bias 的 Weight 参数量是多少 ?
8. 为什么一个 Block 中 MLP 参数可能比 MHA 多 ?
9. `model.eval()` 会关闭 LayerNorm 吗 ? 会关闭 Dropout 吗 ?
10. 判断 : Attention 和 MLP 都会让 Token1 的修改直接改变 Token2 的输出。

参考答案

1. 标准 MLP 只沿最后一个特征维独立作用于每个 (b,t)；没有读取其他 Token 的 hidden state。
2. $fc1=(2,128,3072)$ ， $fc2=(2,128,768)$ 。
3. Residual 是逐元素相加，Shape 必须匹配。
4. $y=x+F(\text{Norm}(x))$ 。
5. $y=\text{Norm}(x+F(x))$ 。
6. Pre-Norm 输出 x ；Post-Norm 输出 $\text{Norm}(x)$ ，一般不等于 x 。
7. $2*768*3072=4,718,592$ 。
8. 经典 MHA 约 $4D^2$ ；若 $D_{ff}=4D$ ，MLP 约 $8D^2$ 。
9. LayerNorm train/eval 行为通常相同；Dropout 在 eval 中关闭。
10. 错。Attention 可以跨 Token；标准 MLP 不会直接跨 Token。

综合 Shape 题

设 $B=4$, $T=256$, $D=1024$, $H=16$, $D_{ff}=4096$ 。写出：

(1) Block 输入；(2) 拆 Head 后 Q ；(3) Attention score；(4) MHA 输出；(5) MLP hidden；(6) Block 输出。

答案

输入= $(4, 256, 1024)$ ； $Q=(4, 16, 256, 64)$ ；score= $(4, 16, 256, 256)$ ；MHA out= $(4, 256, 1024)$ ；MLP hidden= $(4, 256, 4096)$ ；Block out= $(4, 256, 1024)$ 。